

T.C.
KONYA TEKNİK ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ
3. SINIF BAHAR DÖNEMİ
BİLİŞİM TEKNOLOJİLERİ UYGULAMASI ARASINAV/FİNAL(BÜT) RAPORU

Öğrencinin Adı- Soyadı	Aysu Elmas Sude Çoban
Numarası:	231220005 231220031
Danışmanı Adı Soyadı:	Ömer Kaan Baykan
Sınav Tarihi:	11.06.2026
Projenin Adı: Avuç İçi Biyometrik Doğrulama ile Ödeme Sistemi - PalmPay	

DÖNEM İÇİ YAPILAN ÇALIŞMALARIN ÖZETİ

Bu dönem kapsamında, geleneksel ödeme yöntemlerinin (şifre, kart, temaslı biyometri) barındırdığı güvenlik ve hijyen açıklarını gidermek amacıyla; literatürdeki en güncel "Tek Seferlik Öğrenme" (One-Shot Learning) ve "Uç Bilişim" (Edge AI) yaklaşımları temel alınarak temassız bir Avuç İçi Biyometrik Ödeme Sistemi projelendirilmiş ve teknik altyapısı optimize edilmiştir. Biyometrik doğrulama sistemlerinde, kısıtlamasız (unconstrained) ortamlardan alınan görüntülerin analizi kritik bir rol oynamaktadır. Klasik sınıflandırma (Classification) algoritmaları, sisteme her yeni kullanıcı eklendiğinde modelin baştan eğitilmesini (retraining) zorunlu kılmaktadır. Öte yandan, Metrik Öğrenme (Metric Learning) tabanlı Siyam Ağları (Siamese Networks), görüntüleri ezberlemek yerine öznitelik uzayındaki geometrik mesafeleri öğrenerek, daha önce hiç görülmemiş kimliklerin bile saniyeler içinde doğrulanmasına olanak tanır. Bu doğrultuda, derin evrimsel ağların (CNN) güçlü öznitelik yakalama kabiliyeti ile açısız marj (angular margin) optimizasyonunu bir araya getiren hibrit bir mimari kurgulanmış ve sektörel bir FinTech ürününe dönüştürülmüştür.

Gerçekleştirilen çalışmalar şu aşamalardan oluşmaktadır:

1.1. VERİ SETİ TEMİNİ VE YAPISAL ANALİZ

Çalışmada, mobil cihaz kameralarıyla kısıtlamasız ortamlarda toplanan ve literatürde benchmark kabul edilen Sapienza Mobile Palmprint Database (SMPD) kullanılmıştır. Yapılan yapısal analizlerde, ham veri setinin arka plan gürültüleri, açı farklılıkları ve ölçek dengesizlikleri içerdiği saptanmıştır. Dinamik temizleme süreçleri sonucunda 86 farklı bireye ait 2916 yüksek kaliteli avuç içi kesiti elde edilmiştir. Sistemin "One-Shot" kapasitesini kanıtlamak amacıyla, veri kümesi standart rastgele ayırma yerine kişi (ID) bazlı (60 Train / 12 Val / 14 Test) bölünerek, ağır test aşamasında daha önce hiç görmediği kimlikler üzerinde sınanması garanti altına alınmıştır.

1.2. LİTERATÜR ARAŞTIRMASI VE TEORİK TEMELLER

Mobil biyometri ve Siyam ağları üzerine kapsamlı bir kaynak taraması gerçekleştirilmiştir. Özellikle geleneksel ağır siklet modeller (ResNet, VGG) yerine, uç cihazlarda düşük gecikme (low-latency) ile çalışabilen donanım dostu mimarilerin (MobileNetV2) ve ArcFace gibi ileri seviye kayıp fonksiyonlarının entegrasyonu incelenerek projenin teorik çatısı oluşturulmuştur.

1.3. ADAPTİF ÖN İŞLEME (PREPROCESSİNG) PROTOKOLÜ

Kısıtlamasız görüntülerin standartlaştırılması ve modelin öznetelik çıkarımı performansını maksimize etmek amacıyla, MediaPipe ve OpenCV tabanlı çok katmanlı bir boru hattı (pipeline) kurgulanmıştır. Ön işleme süreci aşağıdaki kritik adımlardan oluşmaktadır:

1.3.1. Anatomik Merkez Kaydırma ve Dinamik ROI:

MediaPipe kullanılarak elin 21 eklem noktası tespit edilmiştir. Ancak standart sınır kutularının (bounding box) parmak boğumlarını fazlaca içermesi sorununu aşmak için, geometrik ağırlık merkezi formülleri manipüle edilmiş ($Centroid_{m_{10}/m_{00}}$) ve odak doğrudan saf avuç içi (Core Palm) bölgesine kaydırılmıştır.

1.3.2. İki Aşamalı Mutlak Doğrultma (Affine Rectification):

Görüntülerdeki 90°, 180° gibi aşırı rotasyon sapmalarını gidermek için kaba yönelim hizalaması ve hassas ince ayar aşamaları geliştirilmiş; tüm eller dikey eksene (0°) sabitlenerek modelin açısız asimetrilere etkilenmesi önlenmiştir.

1.3.3. Yansıtılmalı Sınır Dolgusu (Border Reflect):

Kameraya çok yakın çekilen ellerde kırpma karesinin dışa taşmasını engellemek için OpenCV'nin BORDER_REFLECT_101 algoritması uygulanmış, 224x224 matris formu bozulmadan yüzlerce veri kurtarılmıştır.

1.3.4. Fotometrik Optimizasyon ve Kalite Kontrol:

Başlangıçta test edilen CLAHE filtresi, MobileNetV2'nin ImageNet ön-eğitim (pretrained) yapısıyla uyumsuzluk (gradyan kararsızlığı) yarattığından sistemden çıkarılarak doğal RGB uzayına geçilmiştir. Görüntülere %50 cilt pikseli eşiği (QA Threshold) uygulanarak, modele zarar verecek arka plan verileri süzölmüştür.

1.3.5. Boyut Standartlaştırması:

Tüm görüntüler, seçilen ağın küresel standardı olan 224x224 piksel boyutlarına yeniden ölçeklendirilmiş, böylece mikroskobik avuç içi çizgilerinin (wrinkles) kaybolması engellenmiştir.

1.4. UÇTAN UCA YAPAY ZEKA MİMARİSİ VE OPTİMİZASYON

Modelin kalbi olarak, uç cihazlarda yüksek verimlilik sunan MobileNetV2 mimarisi özellik çıkarıcı (encoder) olarak kurgulanmıştır.

1.4.1. Açısız Marj Optimizasyonu:

Standart ikili çapraz entropi (binary crossentropy) yerine, sınıflar arası ayrımı geometrik hiperküre üzerinde maksimize eden ArcFace Katmanı ($m=0.50$) mimariye dahil edilmiştir.

1.4.2. L2 Normalizasyonu:

Özellik çıkarıcıdan elde edilen 128 (512'ye genişletilmiş) boyutlu vektörlerin uzayda dağılmasını önlemek için L2-Norm işlemi uygulanarak vektörel kararlılık sağlanmıştır.

1.4.3. İki Fazlı Eğitim:

Transfer öğrenme sürecinde yıkıcı unutmayı (catastrophic forgetting) engellemek adına; modelin gövdesi önce dondurularak (freeze) baş kısmı eğitilmiş, ardından gövde açılarak düşük öğrenme oranıyla ince ayar (fine-tuning) yapılmıştır.

1.5. GELİŞTİRME ORTAMI VE EDGE AI (Uç Bilişim) DÖNÜŞÜMÜ

Projenin eğitim süreci, yüksek hesaplama maliyetlerini tolere etmek amacıyla Google Colab (Tesla T4 GPU) bulut ortamında asenkron veri yükleyiciler (Data Loaders) ile gerçekleştirilmiştir. Eğitim sonucunda doğrulanan yüksek başarılı model (.pth), doğrudan üretim (production) ortamına alınmamıştır. Finansal bir mobil uygulama hedefine uygun olarak, model ağırlıkları öncelikle donanım bağımsız ONNX statik grafiğine, ardından da Android NPU (Neural Processing Unit) mimarilerinde milisaniyeler içinde çevrimdışı çalışabilmesi için TensorFlow Lite (.tflite) formatına derlenerek uç bilişim (Edge Computing) adaptasyonu tamamlanmıştır.

2.1. PROJENİN AMACI

Bu projenin temel amacı; şifre, PIN kodu veya RFID özellikli fiziksel kartlar gibi geleneksel (geleneksel ve donanım bağımlı) ödeme yöntemlerinin barındırdığı güvenlik zafiyetlerini ortadan kaldırarak; kısıtlamasız (unconstrained) mobil cihaz kameraları üzerinden çalışan, derin öğrenme destekli ve tamamen temassız bir Avuç İçi Biyometrik Ödeme Doğrulama Sistemi geliştirmektir.

Biyometrik sistemlerde temel sorun, çevresel gürültünün (ışık, açı, uzaklık) sistem doğruluğunu dramatik şekilde düşürmesi ve sisteme yeni kullanıcı eklemenin (enrollment) hesaplama maliyetleridir. Bu doğrultuda projenin iteratif geliştirme sürecinde ulaşılan spesifik hedefler şu şekildedir:

2.1.1. Adaptif ve Kayıpsız Biyometrik Veri İzolasyonu

- Kameraya yansıyan kısıtlamasız avuç içi görüntülerinden; elin açısı (rotasyon), mesafesi ve arka plan karmaşası ne olursa olsun salt "saf avuç içi (Core Palm)" verisini izole edecek dinamik bir ön işleme motoru (MediaPipe + Affine Rectification) kurmak.
- Laboratuvar kalitesinde olmayan verileri acımasızca elemek yerine (ilk prototipte %77 veri israfı yaşanmıştır), geometrik yansıtma (cv2.BORDER_REFLECT) ve açı hizalaması algoritmalarıyla "hasarlı veriyi kurtarılabılır hale getirerek" sistemin kullanılabilirlik oranını maksimize etmek.

2.1.2. Kutuplaştırılmış Metrik Öğrenme (Metric Learning) ve Tek Seferlik Öğrenme (One-Shot Learning)

- Dinamik ödeme sistemlerinde sürekli değişen kullanıcı havuzunu yönetebilmek adına, geleneksel çok-sınıflı (Multi-class Classification) modellerin getirdiği "sürekli yeniden eğitim (retraining)" darboğazını aşmak.
- Geliştirme sürecinin erken aşamalarında denenip başarısız olan "İkili Çapraz Entropi (Binary Crossentropy)" ve "Öklid Mesafesi" tabanlı kayıp algoritmaları yerine; sistemin kalbine sektör standardı olan ArcFace (Additive Angular Margin) mimarisini entegre etmek.
- İki avuç içi arasındaki benzerliği, hiperküre üzerinde tanımlanmış 512 boyutlu vektörel uzaklıklar üzerinden kutuplaştırarak (aynı kişi ise %99 benzerlik, farklı kişi ise %0.01 benzerlik), Sisteme yeni eklenen (sıfır veri ile gelen) bir müşterinin bile saniyeler içinde doğrulanmasını (One-Shot Learning) sağlamak.

2.1.3. Uç Bilişim (Edge AI) Optimizasyonu ve Mobil Performans

- Geliştirilen ağır derin öğrenme modellerinin (ResNet) mobil cihazlarda (Flutter/Android) yaratacağı termal ısınma, yüksek gecikme (latency) ve donanım yetersizliklerini öngörerek baştan önlem almak.
- Bu amaçla, sistemin omurgasını (Backbone) baştan itibaren MobileNetV2 mimarisi üzerine inşa etmek. Devamında eğitilen modeli PyTorch (.pth) formatından ONNX ve TensorFlow Lite (.tflite) donanım formatlarına dönüştürerek; internet bağlantısı olmaksızın (offline) doğrudan akıllı telefonun NPU (Neural Processing Unit) veya GPU çipinde çalışan bir prototip ortaya koymak.

2.2. PROJENİN ÖNEMİ

Finansal teknolojilerin (FinTech) dijitalleşme hızı, siber güvenlik açıklarıyla (kimlik hırsızlığı, kart kopyalama) doğru orantılı olarak büyümektedir. Öte yandan, COVID-19 pandemisi sonrası şekillenen "temassız yaşam" kültürü, ortak kullanılan parmak izi okuyucuları gibi temaslı biyometrik sistemlerin hijyenik ömrünü doldurduğunu göstermiştir. Bu bağlamda, geliştirilen sistemin hem akademik literatüre hem de sektörel kullanıma (Industry 4.0) katkıları şu maddelerle özetlenebilir:

2.2.1. Gizlilik ve Anti-Spoofing Direnci

Avuç içi (palmprint) morfolojisi, yüz (facial) veya parmak izine (fingerprint) kıyasla çok daha karmaşık ve taklit edilemez (spoof-proof) bir yapıya sahiptir. Yüzümüz her an kameralara açıkken ve parmak izimiz dokunduğumuz her yüzeyde kalırken; avuç içi çizgileri, doku derinliği ve avuç damar haritası sadece kullanıcının rızasıyla ve belirli bir açıdan kameraya gösterildiğinde elde edilebilir. Geliştirilen bu sistem, "iz bırakmayan" bir biyometrik parametre kullanarak finansal sistemlerdeki kimlik hırsızlığı riskini minimize etmektedir.

2.2.2. Fotometrik ve Vektörel Hataların Aşılması

Derin öğrenme projelerinde sıklıkla yapılan "hazır paketleri veri setine dayatma" hatasından dönülmüş, sistem veriye göre şekillendirilmiştir:

- İlk geliştirme fazında (Phase-1), avuç içi ana hatlarını belirginleştirmek için kullanılan CLAHE (Adaptif Histogram Eşitleme) filtresinin, MobileNetV2'nin yapısıyla uyuşmadığı ve gradyan sönümlenmesine yol açtığı dürüstçe saptanmıştır. Mühendislik müdahalesiyle sistem 3 kanallı doğal RGB uzayına döndürülmüş ve modelin yerel (native) öğrenme potansiyeli maksimize edilmiştir.
- Ham özellik vektörlerinin mesafe katmanında yarattığı ölçek dengesizlikleri, araya eklenen Matematiksel L2 Normalizasyon katmanı ile çözülmüş; vektör uzayı deformasyonu engellenerek modelin karar doğruluğu (Accuracy) durağanlaştırılmıştır.

2.2.3. Donanım ve Hesaplama Maliyetlerinin Radikal Optimizasyonu

Günümüzde "daha büyük model daha iyidir" algısına karşı, bu proje "Model Efficiency (Verimlilik)" konseptini kanıtlamaktadır. Geleneksel ResNet tabanlı mimariler 11-15 Milyon parametre içerirken ve tahmin (inference) süreleri yüzlerce milisaniye sürerken; bu projede özel olarak kurgulanan MobileNetV2 + ArcFace sarmalı sadece ~3.4 Milyon parametre ile benzer (%97) doğruluk seviyelerine ulaşmıştır. Bu hafif sıklet (lightweight) yapı, sistemin standart bir Android akıllı telefon kamerası üzerinden 15-20 milisaniye (30+ FPS) hızında çalışmasını garanti etmektedir.

2.2.4. Pandemi Sonrası Hijyen ve Sosyo-Ekonomik Erişilebilirlik

Sistemin çalışması için LiDAR sensörlerine, kızılötesi (IR) kameralara veya pahalı biyometrik okuyuculara ihtiyaç yoktur. Standart bir RGB akıllı telefon kamerası, doğrulama işlemi için yeterlidir. Bu durum, altyapısı gelişmemiş bölgelerdeki (kırsal alanlar) işletmelerin bile yüksek maliyetli POS cihazları satın almadan, sadece bir mobil uygulama indirerek biyometrik ve temassız ödeme alabilmesinin önünü açmaktadır.

2.2.5. Literatüre Metodolojik Katkı (Two-Phase Transfer Learning)

Siyam Ağlarının uçtan uca (end-to-end) eğitiminde yaşanan zorluklar, literatürde sıklıkla raporlanmaktadır. Projemizde uygulanan; ağın gövdesini (backbone) dondurup sadece baş kısmını (head) eğitme (Faz 1) ve ardından tüm yapıyı düşük öğrenme oranıyla ince ayara (Faz 2) sokma stratejisi, kısıtlı veriye sahip (Data Scarcity) diğer biyometri projeleri için akademik bir rehber niteliği taşımaktadır.

KAYNAK ARAŞTIRMASI

Temassız avuç içi biyometrisi, metrik öğrenme tabanlı Siyam Ağları ve mobil derin öğrenme mimarileri üzerine kapsamlı bir literatür taraması gerçekleştirilmiştir. Bu taramanın temel amacı; mevcut yaklaşımların kısıtlarını sistematik biçimde ortaya koymak, projede benimsenen "MediaPipe Ön İşleme Motoru + MobileNetV2 Omurgalı Siyam Ağı + ArcFace" hibrit mimarisinin literatürdeki boşluğu nasıl doldurduğunu konumlandırmak ve kullanılan tüm yöntemlerin bilimsel dayanaklarını belgelemektir. İncelenen kaynaklar; veri seti altyapısından mimari seçimlere, kayıp fonksiyonlarından geliştirme araçlarına kadar projenin tüm teknik katmanlarını kapsamaktadır.

3.1. Izadpanahkakhk vd. (2019) [12] ve Izadpanahkakhk vd. (2021) [13] — Kısıtlamasız Mobil Avuç İçi Veri Seti ve Derin Öğrenme Temelli Tanıma

Çalışmanın Kapsamı ve Veri Seti: Literatüre kısıtlamasız mobil avuç içi veri setini kazandıran bu öncü çalışmada Izadpanahkakhk vd. [12], akıllı telefon kameralarıyla farklı açı ve arka planlardan çekilen gerçek dünya görüntülerini kapsayan Sapienza Mobile Palmprint Database'i (SMPD) oluşturmuştur. Geleneksel laboratuvar veri setlerinin (sabit ışık, dokunmatik tarayıcı) aksine SMPD, 92 bireye ait 3.680 görüntüyle değişken ışık, rotasyon ve arka plan koşullarını temsil etmektedir. Devam niteliğindeki ikinci çalışmada [13] ise aynı veri seti üzerinde AlexNet, VGG-16 ve ResNet-50 gibi ağır CNN mimarileri transfer öğrenme ile test edilmiş; ResNet-50 ile Softmax ve SVM kombinasyonu kullanılarak %97'nin üzerinde doğruluk elde edilmiştir.

Projemizdeki Rolü: SMPD veri seti [12], projemizin eğitim, doğrulama ve test aşamalarının temel hammaddesini oluşturmaktadır. Ham 3.677 görüntü üzerinde geliştirilen Adaptif ROI Motoru ve QA filtreleme algoritmaları işletilerek 2.916 yüksek kaliteli avuç içi kesiti elde edilmiştir. [13]'teki yaklaşımın iki temel kısıtı — ağır CNN mimarisinin (ResNet-50) mobil cihazlarda kabul edilemez gecikme süreleri yaratması ve çok sınıflı yapının her yeni kullanıcıda yeniden eğitim gerektirmesi — projemizin MobileNetV2 [8] omurgalı Siyam Ağı [3] mimarisine yönelmesinin doğrudan motivasyonunu oluşturmıştır.

3.2. Ungureanu vd. (2020) [16] ve Alausa vd. (2022) [17] — Kısıtlamasız Avuç İçi Tanıma Derleme Çalışmaları

Çalışmanın Kapsamı: Ungureanu vd. [16], tüketici cihazlarında kısıtlamasız avuç içi tanıma yöntemlerini kapsamlı biçimde inceleyen bir derleme makalesidir. ROI çıkarım algoritmaları, öz nitelik çıkarım yaklaşımları ve mevcut veri setleri karşılaştırmalı olarak değerlendirilmiş; parmak izi ve yüze kıyasla avuç izinin sunduğu gizlilik avantajları tartışılmıştır. Alausa vd. [17] ise temaslı ve temassız avuç içi sistemlerini sistematik biçimde karşılaştıran, ROI çıkarımı ve eşleştirme algoritmalarının performanslarını değerlendiren güncel bir derleme sunmaktadır.

Projemizdeki Rolü: Her iki derleme çalışması, projemizin teorik çerçevesini oluştururken birincil referans kaynakları olarak kullanılmıştır. Avuç içinin biyometrik sisteme uygunluğunu gerekçelendiren "Gizlilik ve Anti-Spoofing Direnci" argümanı (Bölüm 2.2.1) [16]'daki bulgulara dayanmaktadır. Kısıtlamasız ortam koşullarının neden özel bir ROI motoru gerektirdiği [16] [17]'deki analizlerle desteklenmekte; Adaptif HSV-Centroid Motorumuzun neden standart sabit kırpma yöntemlerinin ötesine geçmek zorunda olduğu bu çalışmalar referans alınarak açıklanmaktadır.

3.3. Grosz vd. (2024) [15] ve Kim vd. (2015) [14] — Mobil Avuç İçi Tanımda Güncel Başarım Sınırları

Çalışmanın Kapsamı: Grosz vd. [15], Vision Transformer (ViT) ve CNN'i birleştiren çok ölçekli, çok modelli Palm-ID sistemini sunmaktadır. 18 ms'de 516 baytlık biyometrik şablon üreten bu sistem, 10.000 avuç içi galerisinde 0.33 ms'de arama yapabilmekte ve %98.06 TAR @ FAR=0.01% başarımıyla güncel sınırları belgelemektedir. Kim vd. [14] ise mobil telefon kameralarıyla avuç içi tanımayı ampirik olarak test eden erken dönem bir çalışma olup değişken çekim koşullarının (ışık, açı, mesafe) tanıma performansına etkisini sayısal olarak ortaya koymuştur.

Projemizdeki Rolü: [15], projemizin ulaşmayı hedeflediği üretim ortamı (production-ready) başarım sınırını tanımlamaktadır. Projemiz benzer hesaplama kısıtları altında farklı bir mimari tercih (MobileNetV2 [8] + ArcFace [5]) ile bu seviyeye yaklaşmakta olup 11.5 MB'lık TFLite modeli ve 25 ms gecikme süresi rakamsal olarak kıyaslanabilir bir başarım sunmaktadır. [14] ise Bölüm 2.1.1'de tanımlanan "kısıtlamasız ortam" probleminin pratik boyutlarını — farklı kamera kalibrasyonlarının ve çekim mesafelerinin sisteme etkisini — somutlaştırmak amacıyla incelenmiştir.

3.4. Bromley vd. (1993) [2] ve Koch vd. (2015) [3] — Siyam Ağlarının Temelleri ve Tek Seferlik Öğrenme

Çalışmanın Kapsamı: Siyam Ağı kavramının literatüre girişini sağlayan Bromley vd. [2], imza doğrulama problemini çözmek için ağırlıkları paylaşan iki paralel ağı ve aralarındaki mesafeyi hesaplayan bir birleştirici nöron içeren mimariyi ilk kez tanımlamıştır. Bu kurucu mimari üzerine inşa edilen Koch vd. [3], derin evrimsel Siyam Ağlarının "Tek Seferlik Öğrenme (One-Shot Learning)" kapasitesini kanıtlamış; modelin eğitim sırasında hiç görmediği sınıflarda bile doğrulama yapabileceğini, doğrulama performansının one-shot sınıflandırma ile doğrudan ilişkilendirilebileceğini göstermiştir.

Projemizdeki Rolü: [2]'deki "ağırlık paylaşımı" prensibi ve [3]'teki "one-shot" paradigması, projemizin temel mimari kararını doğrudan şekillendirmiştir. Dinamik bir ödeme sisteminde kullanıcı tabanının sürekli değişmesi, [3]'teki one-shot özelliği sayesinde her yeni kullanıcı kaydında modelin yeniden eğitilmesine gerek kalmaksızın sıfır veriyle doğrulama yapılabilmesini sağlamaktadır. Projemizin özellik çıkarıcı omurgası olarak seçilen MobileNetV2 [8], bu mimari şema içinde iki özdeş paralel dal şeklinde konumlandırılmış; her dal giriş görüntüsünü 512 boyutlu bir biyometrik kimlik vektörüne dönüştürmektedir.

3.5. Schroff vd. (2015) [4] — FaceNet ve Triplet Loss: Metrik Öğrenmede Ara Basamak

Çalışmanın Kapsamı: Schroff vd. [4], görüntüleri doğrudan bir Öklid uzayına eşleyen ve bu uzaydaki mesafelerin yüz benzerliğini temsil ettiği birleşik bir gömme (embedding) çerçevesi sunmaktadır. Yeniliği olan Triplet Loss, üçer üçer seçilen (anchor, pozitif, negatif) örnekler üzerinden eğitim yaparak sınıf içi mesafeyi küçültürken sınıflar arası mesafeyi belirli bir marjın ötesine iterek ayırıcı bir uzay oluşturmayı hedefler. LFW veri setinde %99.63 doğruluk elde etmiştir.

Projemizdeki Rolü: Projemizin ilk geliştirme fazında Contrastive Loss ve [4]'teki Triplet Loss yaklaşımı avuç içi doğrulama problemine uygulanmış; ancak yüksek boyutlu avuç içi uzayında vektörlerin 0.40–0.60 benzerlik aralığında yığılması ve gradyan sönümlenmesi gözlemlenmiştir. Bu deneysel başarısızlık, [5]'teki ArcFace kayıp fonksiyonuna geçişin temel motivasyonunu oluşturmuştur. [4]'ün incelenmesi, Öklid mesafesine dayalı yaklaşımların kısıtlarını anlamamızı ve kosinüs benzerliği ile açısız marj kombinasyonunun [5] avuç içi gibi ince dokusal örüntülere sahip biyometrik verilerde neden daha üstün olduğunu gerekçelendirmemizi sağlamıştır.

3.6. Deng vd. (2019) [5] — ArcFace ve Açısal Marj Optimizasyonu

Çalışmanın Kapsamı: Deng vd. [5], öznitelik vektörlerinin L2 normalizasyonu ile birim hiperküre üzerine izdüşürüldüğü ve sınıflar arasındaki mesafenin geometrik bir açısal marj eklenerek maksimize edildiği ArcFace (Additive Angular Margin Loss) kayıp fonksiyonunu tanıtmaktadır. Yüz tanıma için geliştirilmiş bu yöntem, [4]'teki Triplet Loss ve Contrastive Loss'un yetersiz kaldığı durumlarda güçlü sınıflar arası ayrım sağlamaktadır. Karar sınırı oluşturmak yerine her sınıf merkeziyle hedef vektör arasındaki açığa ek bir marj (m) uygulanması yöntemin temel yeniliğini oluşturmaktadır.

Projemizdeki Rolü: [5], projemizin en özgün mühendislik katkısının kaynağıdır. Yüz tanıma için tasarlanan ArcFace katmanı ($m=0.50$, $s=64.0$), projemizde avuç içi doğrulama problemine uyarlanmıştır. Bu uyarılama sayesinde aynı bireye ait avuç içleri vektör uzayında ortalama 0.475, farklı bireylere ait avuç içleri ise yalnızca 0.020 benzerlik skoruna ulaşmıştır. Bu devasa kutuplaşma (polarizasyon), sisteme daha önce hiç eklenmemiş kullanıcıların dahi başarıyla doğrulanmasını mümkün kılmış; EER analizinde 0.224 eşik değerine ulaşılmıştır. [5]'in önerdiği L2 normalizasyonu ayrıca MobileNetV2 [8] çıkışındaki 512 boyutlu vektörlerin ölçek bağımsız karşılaştırılmasını sağlayan ayrı bir katmanın tasarım dayanağını da oluşturmaktadır.

3.7. He vd. (2016) [6] ve Howard vd. (2017) [7] — Artık Öğrenme ve Mobil Mimarinin Evrimi

Çalışmanın Kapsamı: He vd. [6], 2016 CVPR En İyi Makale Ödülü'ne layık görülen bu çalışmada kısa yol bağlantıları (shortcut connections) aracılığıyla derin ağlardaki gradyan sönümlenmesi sorununu çözen ResNet mimarisini tanıtmaktadır. 152 katmana kadar derinleşen ve ILSVRC 2015'te birinci olan bu model, derin öğrenmede temel referans noktası haline gelmiştir. Howard vd. [7] ise standart 3×3 evrişimleri Derinlemesine Ayrılabilir Evrişimlere (Depthwise Separable Convolutions) bölerek hesaplama maliyetini 8–9 kat düşüren MobileNets'in ilk versiyonunu sunmaktadır.

Projemizdeki Rolü: [6]'daki ResNet-18, projemizde karşılaştırmalı mimari analizi için incelenmiştir. Orta seviye bir akıllı telefon işlemcisinde (Snapdragon 680 sınıfı) 320 ms gecikme üretmesi ve TFLite [18] dönüşümü sonrası 45 MB model boyutuna ulaşması, gerçek zamanlı mobil ödeme senaryosu için kabul edilemez olduğunu kanıtlamıştır. [7]'deki Depthwise Separable Convolution yeniliği, projemizin omurgası MobileNetV2 [8]'nin hesaplama verimliliğinin temel mimarı kavramsal dayanağını oluşturmakta ve ağı parametre sayısını ~3.4 Milyon düzeyinde tutarak TFLite [18] dönüşümüne zemin hazırlamaktadır.

3.8. Sandler vd. (2018) [8] — MobileNetV2: Üretim Ortamı Omurgası

Çalışmanın Kapsamı: Sandler vd. [8], Ters Çevrilmiş Artık Bloklar (Inverted Residual Blocks) ve Doğrusal Darboğaz Katmanları (Linear Bottlenecks) ile [7]'yi geliştiren MobileNetV2'yi sunmaktadır. Genişleme faktörü $t=6$ olan mimari; blok içi temsil kapasitesini artırırken kısa yol bağlantısını yalnızca dar giriş-çıkış kanalları arasında tutarak bellek kullanımını optimize etmektedir. TFLite [18] ekosistemiyle doğal uyumluluğu ve ImageNet üzerinde 1.2 milyon görüntüyle ön-eğitilmiş ağırlıklara sahip olması öne çıkan özelliklerdir.

Projemizdeki Rolü: [8], projemizin Siyam Ağı [3] mimarisindeki iki paralel dalın omurgasıdır (encoder/backbone). Her dal özdeş MobileNetV2 ağırlıklarını paylaşmakta; 1280 boyutlu Global Average Pooling çıktısı 512 nöronlu Bottleneck katmanından ve L2 normalizasyonundan [5] geçirilerek ArcFace kaybına hazır hale getirilmektedir. Aynı donanımda [6] ile kıyaslandığında gecikmeyi 320 ms'den 25 ms'ye indirmesi ve iki fazlı transfer öğrenme stratejisiyle [1][21] avuç içi dokusu tanıma görevine etkin biçimde uyarlanabilmesi, bu mimariyi mobil ödeme uygulaması için belirleyici kılmıştır.

3.9. Lugaresi vd. (2019) [9] — MediaPipe: Gerçek Zamanlı Landmark Tespiti

Çalışmanın Kapsamı: Google araştırmacıları tarafından sunulan MediaPipe [9], gerçek zamanlı algı ve makine öğrenmesi boru hatları kurmak için tasarlanmış platform bağımsız bir çerçevedir. İçerdiği Hand Landmark modeli, el iskeletindeki 21 anatomik noktayı piksel koordinatlarıyla düşük gecikmeyle tahmin edebilmektedir. Çapraz platform desteği ve düşük bellek ayak izi öne çıkan özellikleridir.

Projemizdeki Rolü: [9], projemizin Adaptif ROI Motorunun birincil bileşenini oluşturmaktadır. Ancak [9]'un standart çıktıları doğrudan kullanılmamıştır: standart sınır kutularının parmak boğumlarını fazlaca içermesi sorununu aşmak amacıyla tespit edilen 21 eklem noktasının geometrik ağırlık merkezi formülleri (Centroid: m_{10}/m_{00}) manipüle edilerek odak, parmak bölgesinden saf avuç içi (Core Palm) bölgesine kaydırılmıştır. [16][17]'deki analizlerin işaret ettiği kısıtlamasız ortam koşullarında [9]'un el iskeletini tespit edemediği zorlu görüntülerde ise geliştirilen Adaptif HSV-Centroid yedekleme (fallback) mekanizması devreye girerek veri kaybını sıfıra indirmiştir.

3.10. Yosinski vd. (2014) [21] — Transfer Öğrenmenin Aktarılabirlik Analizi ve İki Fazlı Eğitimin Teorik Gerekçesi

Çalışmanın Kapsamı: Yosinski vd. [21], derin sinir ağlarında öğrenilen özneteliklerin katmandan katmana nasıl değiştiğini ve farklı görevler arasında ne ölçüde aktarılabir olduğunu sistematik biçimde inceleyen, alana yön veren bir NeurIPS çalışmasıdır. Erken katmanlardaki özneteliklerin (kenar, renk, dokusal gradyan) görevden bağımsız genel (general) karakterde; son katmanlardaki özneteliklerin ise göreve özgü (task-specific) karakterde olduğu deneysel olarak kanıtlanmıştır. Öte yandan "yıkıcı unutma (catastrophic forgetting)" riski nedeniyle transfer öğrenmede omurganın tümüyle serbest bırakılması yerine kademeli açma (gradual unfreezing) stratejisinin daha kararlı yakınsama (convergence) sağladığı gösterilmiştir.

Projemizdeki Rolü: [21], projemizin MobileNetV2 [8] omurgası üzerinde uygulanan iki fazlı transfer öğrenme stratejisinin birincil teorik dayanağını oluşturmaktadır. Strateji şu şekilde tasarlanmıştır: Faz 1'de (1–10. epoklar, LR=1e-3) omurga dondurularak yalnızca Bottleneck ve ArcFace [5] başlığı eğitilmiş; bu sayede ImageNet ön-eğitiminden gelen genel görsel temsiller [21]'in tarif ettiği yıkıcı unutma riski olmaksızın korunmuştur. Faz 2'de (11–43. epoklar, LR=1e-4) tüm model serbest bırakılmış ve avuç içi dokusu için özelleştirilmiş ince ayar (fine-tuning) uygulanmıştır. Bu kademeli açma yaklaşımının gerekçesi doğrudan [21]'deki aktarılabirlik analizine dayanmaktadır: erken katmanlardaki genel öznetelikler kısıtlamasız mobil görüntülerde de geçerliyken, son katmanların yeniden özelleştirilmesi avuç içi biyometrisine özgü ince dokusal örüntülerin [12] yakalanmasını mümkün kılmaktadır.

3.11. Goodfellow vd. (2016) [1] — Derin Öğrenme: Teorik Referans Kaynağı

Çalışmanın Kapsamı: Goodfellow, Bengio ve Courville'in kaleme aldığı bu eser [1], derin öğrenme alanının standart referans kitabıdır ve ücretsiz olarak çevrimiçi erişime açıktır. CNN mimarileri, geri yayılım (backpropagation), kayıp fonksiyonları, düzenlileştirme (regularization), optimizasyon algoritmaları ve transfer öğrenme gibi temel konuları kapsamlı ve matematiksel düzeyde ele almaktadır.

Projemizdeki Rolü: Tüm rapor genelinde kullanılan matematiksel notasyonlar, kayıp fonksiyonu türevleri ve temel öğrenme teorisi kavramları birincil kaynak olarak [1]'e dayanmaktadır. Özellikle Bottleneck katmanındaki L2 normalizasyonu ile ArcFace'in [5] hiperküre geometrisi arasındaki ilişkinin açıklanmasında; iki fazlı transfer öğrenme stratejisinin "yıkıcı unutma (catastrophic forgetting)" bağlamında ele alınmasında ve MobileNetV2'nin [8] biyometrik doku temsil yeterliliğinin teorik gerekçelendirilmesinde temel başvuru kaynağı olarak kullanılmıştır.

KAYNAK ARAŞTIRMASI

3.12. Paszke vd. (2019) [10] ve Abadi vd. (2016) [11] — Derin Öğrenme Geliştirme Çerçeveleri

Çalışmanın Kapsamı: Paszke vd. [10], dinamik hesaplama grafları kullanan Python tabanlı PyTorch kütüphanesini tanıtmaktadır. Zorunlu (imperative) programlama paradigması, kolay hata ayıklama ve GPU hızlandırma öne çıkan özellikleridir. Abadi vd. [11] ise veri akış grafi (dataflow graph) temelli büyük ölçekli makine öğrenmesi sistemini ve mobil dağıtım için TFLite [18] alt kütüphanesini kapsayan TensorFlow platformunun kurucu çalışmasıdır.

Projemizdeki Rolü: Siyam Ağı mimarisi, ArcFace [5] katmanı ve iki fazlı eğitim stratejisinin tümü [10] (PyTorch) üzerinde Google Colab ortamında (Tesla T4 GPU) geliştirilmiştir. Eğitilen model .pth formatında kaydedildikten sonra [19] (ONNX) köprüsü aracılığıyla [11] (TensorFlow/TFLite [18]) ekosistemine taşınmıştır. Flutter [20] uygulamasında biyometrik çıkarım (inference) işlemleri TFLite Interpreter üzerinden gerçekleştirilmekte; kullanıcının avuç içi verisi hiçbir zaman cihaz dışına çıkmamaktadır.

3.13. Google TFLite [18], ONNX [19] ve Flutter [20] — Dağıtım Altyapısı ve Mobil Çerçeve

Çalışmanın Kapsamı: TFLite [18], TensorFlow modellerini mobil ve gömülü cihazlarda düşük gecikme ile çalıştırmak için optimize edilmiş; NNAPI ve GPU Delegate donanım hızlandırmayı destekleyen çapraz platform bir çerçevedir. ONNX [19], farklı derin öğrenme çerçeveleri (PyTorch, TensorFlow vb.) arasında model taşınabilirliği sağlayan, Facebook ve Microsoft tarafından başlatılıp Linux Foundation bünyesinde yönetilen açık kaynaklı bir format standardıdır. Flutter [20], Google'ın geliştirdiği ve tek Dart kod tabanından Android, iOS ve masaüstü platformlarına derleme yapılabilen, Skia grafik kütüphanesi üzerine inşa edilmiş UI çerçevesidir.

Projemizdeki Rolü: PyTorch'tan [10] TFLite'a [18] doğrudan dönüşüm mümkün olmadığından iki aşamalı köprü mimarisi uygulanmıştır: PyTorch → [19] ONNX (torch.onnx.export, opset 11; onnxsim ile sadeleştirme ve sabit katlanma optimizasyonu) → [18] TFLite (onnx2tf ile SavedModel, ardından TFLite formatına derleme; girdi [1, 224, 224, 3], çıktı [1, 512], 11.5 MB). Tüm bu zincir, PalmPay mobil uygulamasını barındıran [20] Flutter projesine entegre edilmiştir. Sonuç olarak biyometrik doğrulama işlemleri, KVKK uyumluluğu kapsamında internet bağlantısı gerektirmeksizin cihaz üzerinde (on-device) milisaniyeler içinde gerçekleştirilmektedir.

3.14. Literatür Karşılaştırma Özeti

İncelenen literatür bütüncül olarak değerlendirildiğinde üç temel eğilim dikkat çekmektedir.

Veri ve Model Ağırlığı: SMPD üzerinde çalışan modeller [12][13] yüksek doğruluk üretmekte; ancak ResNet-50 gibi ağır mimarilerin mobil cihazlarda hesaplama kısıtlarını aşamaması, üretim ortamına entegrasyonu engellemektedir. [15]'teki Palm-ID sistemi gecikme sorununu büyük ölçüde çözmüş olsa da çok modellenli yapısı dağıtım karmaşıklığını artırmaktadır. Öte yandan [14], gerçek dünya mobil çekim koşullarının tanıma performansını nasıl etkilediğini ampirik olarak ortaya koymuştur.

Öğrenme Pratiği: Siyam ağları [2][3] one-shot öğrenme için güçlü bir çerçeve sunsa da Triplet Loss [4] ve Contrastive Loss gibi klasik kayıp fonksiyonları, yüksek boyutlu avuç içi uzayında vektörlerin yeterince ayrıştırılamaması sorunuyla karşılaşmaktadır. [5]'teki ArcFace bu sınırı geometrik açısal marj ile aşmakla birlikte, orijinalinde yüz tanıma için tasarlandığından avuç içi biyometrisine uyarlanması özgün bir mühendislik çabası gerektirmiştir.

Ön İşleme: Kısıtlamasız görüntülerin standart sabit kırpmayla modele verilmesinin rotasyon ve açı bozulmaları nedeniyle aşırı öğrenmeye (overfitting) yol açtığı [16][17]'de kapsamlı biçimde raporlanmıştır. [9]'un sağladığı landmark tespiti güçlü bir başlangıç noktası sunsa da kısıtlamasız ortamların oluşturduğu zorluklar (düşük ışık, elin kadraja tam sığmaması) adaptif yedekleme mekanizmaları geliştirmeyi zorunlu kılmıştır.

3.15. Sentez: Literatürdeki Boşluk ve Bu Projenin Konumu

Literatürdeki çalışmalar genel olarak ya yüksek doğruluklu ancak mobil dışı modeller [12][13][6] ya da hafif ancak sınırlı biyometrik ayırım kapasitesine sahip mimariler üzerine odaklanmış olup gerçek dünya koşullarında çalışacak uçtan uca (end-to-end) mobil biyometrik ödeme entegrasyonunda ciddi bir boşluk bırakmaktadır: yüksek doğruluk elde eden modeller mobil cihaza sığmamakta, mobil cihaza sığan hafif modeller ise yeterli biyometrik ayırım yapamamaktadır.

Bu proje söz konusu açmazları eş zamanlı olarak çözen özgün bir boru hattı sunmaktadır:

Dinamik Ön İşleme (MediaPipe + Affine Rectification): [9]'un standart çıktısının ötesine geçen Adaptif ROI + HSV-Centroid motoru, hatalı ve zorlu verileri kurtarılabilir hale getirerek MediaPipe'in %25 başarıda kaldığı senaryolarda %100 biyometrik kırpma başarısı elde etmiştir.

Siyam-ArcFace Entegrasyonu: [5]'teki ArcFace yüz tanıma bağlamından çıkarılıp [3]'teki Siyam çerçevesine entegre edilerek avuç içi doğrulama problemine uyarlanmıştır. Bu sayede [4]'teki Triplet Loss'un yetersiz kaldığı durumlarda aynı kişi ≈ 0.475 , farklı kişi ≈ 0.020 kutuplaşması sağlanmıştır.

TFLite ile Uç Bilişim: [8] + [10] $\rightarrow$ [19] $\rightarrow$ [18] zinciri, [11] ekosistemi aracılığıyla [20]'ye entegre edilmiş; 11.5 MB boyutunda, 25 ms gecikmeli ve çevrimdışı çalışan üretim ortamı modeli elde edilmiştir.

Bu bölümde, projenin kavramsal aşamadan uçtan uca çalışan bir temassız ödeme simülasyonuna dönüştürülme sürecinde kullanılan veri seti optimizasyonları, algoritmik boru hatları (pipelines) ve derin öğrenme mimarileri detaylandırılmıştır. Geliştirme süreci; doğrusal ilerleyen bir yapıdan ziyade, modelin verdiği tepkilere göre şekillenen iteratif (deneme-yanılma tabanlı) bir mühendislik yaklaşımıyla yürütülmüştür.

4.1. MATERYAL: VERİ SETİ ANALİZİ (SAPIENZA MOBILE PALMPRINT DATABASE - SMPD)

Bu çalışmada, biyometrik sistemlerin gerçek dünya (real-world) koşullarındaki dayanıklılığını ölçmek amacıyla literatürde kısıtlamasız (unconstrained) mobil avuç içi biyometrisi için referans kabul edilen Sapienza Mobile Palmprint Database (SMPD) kullanılmıştır. Klasik laboratuvar veri setlerinin (sabit ışık, tarayıcı cihazı vb.) aksine, bu veri seti akıllı telefon kameralarıyla farklı arka planlarda, değişen ışık koşullarında ve serbest açılarla toplanmıştır.

4.1.1. Veri Seti Dosya Yapısı ve Görüntü İsimlendirme Sistemi

Ham veri seti, data/raw/SMPD/ kök dizini altında hiyerarşik bir klasör yapısında organize edilmiştir. Yapı; 3 seviyeli bir dizin ağacından oluşmaktadır:




Şekil 4.1.1.1 Veri Seti Dosya Yapısı

Her üst klasör, üç haneli sıfır dolgulu (zero-padded) bir kimlik numarası (001–093) ile isimlendirilmiş olup bir bireyi (subject) temsil etmektedir. Veri setinde 054 numaralı subject bulunmamakta; bu durum orijinal SMPD kayıt sürecindeki veri toplama kısıtlamalarından kaynaklanmaktadır. Sonuç olarak veri seti, fiilen 92 farklı bireye ait görüntüler içermektedir.

- **Görüntü İsimlendirme Kuralı**

Her görüntü dosyası, üç parçadan oluşan tutarlı bir isimlendirme şemasına sahiptir:



Şekil 4.1.1.2. Görüntü İsimlendirme Sistemi

4.1.2. Çekim Türleri ve Biyometrik Kapsam

SMPD veri seti, her birey için 4 farklı çekim türünde ve her türden 10'ar görüntü olmak üzere toplamda birey başına 40 görüntü sunmaktadır:

Çekim türleri			
Kısaltma	Açılım	El / Yön	Numara
F	Front	Sol el — el sırtı	0 - 9
RF	Right Front	Sağ el — el sırtı	10 - 19
P	Palm	Sol el — avuç içi ★	20 - 29
RP	Right Palm	Sağ el — avuç içi ★	30 - 39

★ Adaptif ROI Motoru tarafından işlenen hedef kategoriler

Şekil 4.1.2.1. Görüntü İsimlendirme Sistemi

Biyometrik doğrulama sistemimizin temel girdisini avuç içi dokusu ve çizgi morfolojisi oluşturduğundan, geliştirilen "Adaptif ROI Motoru" yalnızca P ve RP kategorilerindeki görüntüleri (birey başına 20 görüntü) işleme almayı hedeflemiştir. F ve RF kategorileri (el sırtı görüntüleri) avuç içi biyometrisine doğrudan katkı sunmadığından, MediaPipe ROI kalite filtresinin uygulanması sırasında büyük ölçüde eleme dışı bırakılmıştır.

4.1.3. Veri Seti İstatistikleri ve Kalite Filtreleme



Şekil 4.1.3.1. Görüntü İsimlendirme Sistemi

Ham veri setindeki 3.677 görüntü, geliştirilen 'Adaptif ROI Motoru' ve '%50 Cilt Kapsamı' (QA Filter) mekanizmalarından geçirilmiştir. Sistemin biyometrik doğruluk (accuracy) performansını korumak amacıyla; aşırı bulanık (motion blur), yetersiz cilt dokusuna sahip veya MediaPipe el-iskelet (landmark) tespitinin güven eşiğinin (<0.7) altında kalan toplam 761 görüntü otomatik olarak ayıklanmış, 2.916 adet yüksek nitelikli avuç içi kesiti (ROI) model eğitimine dahil edilmiştir.


Veri setinin analizi ve projeye entegrasyon süreci şu parametreler üzerinden yapılandırılmıştır:

- **Katılımcı Profili:** Ham veri setinde 92 farklı bireye ait görüntüler bulunmasına rağmen; projemizde geliştirilen "Kalite Kontrol (QA) ve Deri Pikseli Filtresi (%50 Cilt Kapsamı)" algoritmasından başarıyla geçebilen 86 farklı birey (Subject) çalışma kümesine dahil edilmiştir. Düşük kaliteli veya aşırı bulanık olan 6 birey, modelin kararlılığını korumak amacıyla sistemden bilinçli olarak izole edilmiştir.
- **Veri Yapısı ve Hacmi:** Geliştirilen "Adaptif ROI Motoru" işlemleri sonucunda, sistemde toplam 2.916 adet yüksek kaliteli avuç içi kesiti (slice) elde edilmiştir. Ham veri setindeki farklı çözünürlüğe sahip görüntüler, MobileNetV2 ağının optik algısına uygun olacak şekilde 224x224x3 (RGB) boyutlarına standardize edilmiştir.
- **Veri Seçimi ve Dağılım İstatistiği:** Modelin kısıtlamasız ortam şartlarını öğrenebilmesi için her bireyin farklı açılardan çekilmiş görüntüleri kullanılmıştır. İşlemler sonucunda her denekten (bireyden) ortalama 33.9 adet temsili avuç içi ROI kesiti sisteme kazandırılmıştır.
- **Sınıf Dağılımı ve ID-Bazlı (Subject-Wise) Veri Bölümleme Stratejisi:** Geleneksel derin öğrenme projelerinde veri seti, resimler üzerinden rastgele (random) oranlarda bölünür. Ancak bu yöntem, aynı kişiye ait farklı açıdaki resimlerin hem Eğitim hem de Test setine düşmesine (Bilgi Sızıntısı / Data Leakage) yol açar. Projemizin temel amacı "Daha önce hiç görülmemiş bir eli anında doğrulamak (One-Shot Learning)" olduğu için, veri seti rastgele resimler üzerinden değil, Kimlikler (ID) üzerinden katı bir şekilde bölünmüştür:

MATERYAL VE METOT

- Eğitim Seti (Train): 60 Kişi / 2.082 Görüntü (Modelin özellikleri öğrendiği ve ArcFace sınıf ağırlıklarının optimize edildiği ana havuz).
- Doğrulama Seti (Validation): 12 Kişi / 338 Görüntü (Eğitim sırasında modelin ezberlemesini önlemek ve hiperparametre ayarı yapmak için ayrılan havuz).
- Test Seti (Test): 14 Kişi / 496 Görüntü (Modelin eğitim sırasında hiç görmediği, EER (Hata Eşitlik Oranı) analizinin ve canlı simülasyonların yapıldığı dokunulmaz havuz).

Bu katı "ID-Bazlı" bölümlleme stratejisi, modelin sadece eğitim setindeki kişileri ezberlemediğini; aksine avuç içi morfolojisini (çizgiler, dokular) matematiksel olarak öğrenerek, sisteme yeni eklenen (sıfır veriyle gelen) herhangi bir kullanıcıyı da başarıyla doğrulayabileceğini kanıtlamaktadır.



Şekil 4.1.3.2. SMPD Veri Seti Analizi ve ID-Bazlı (Sızıntısız) Bölümlleme Stratejisi

4.1.4. Görsel Örneklem ve Kısıtlamasız Ortam (Unconstrained) Varyasyonu

SMPD veri setindeki görüntüler, laboratuvar ortamındaki biyometrik veri toplama süreçlerinin aksine, yüksek derecede çekim varyansına (imaging variance) sahiptir. Şekil 4.3'te görüldüğü üzere; aynı bireyin farklı görüntülerinde bile ışık yoğunluğu, kameraya olan mesafe, elin rotasyon açısı ve arka planın parlaklık değeri (özellikle Subject 030 gibi uç örneklerde görülen aşırı pozlama) birbirinden ciddi farklılıklar göstermektedir.

Bu durum, literatürde "Kısıtlamasız Ortam (Unconstrained Environment)" olarak tanımlanmaktadır. Geliştirdiğimiz "Adaptif ROI Motoru" ve "QA Filtresi", bu tip uç (outlier) örnekleri;

- Pozlama Dengesizlikleri: Subject 030 gibi aşırı parlak veya kontrastı düşük görüntülerdeki öznitelik kaybını, biyometrik kalite kontrol (QA) filtresi ile süzerek modele girmeden ayıklamıştır.
- Geometrik Bozulmalar: Subject 080 örneğindeki gibi elin eğik veya kırpık tutulduğu durumlar, geliştirilen afin dönüşüm ve anatomik merkezleme (Core Palm Focus) algoritmalarıyla geometrik olarak düzeltilmiştir.

Dolayısıyla veri seti, "gürültülü" bir veri havuzu değil; gerçek hayattaki mobil kullanıcıların (herhangi bir ışıpta, herhangi bir açıda tutan kullanıcıların) oluşturduğu "yüksek varyanslı" bir biyometrik test düzeneğidir. Sistemin başarısı, bu tutarsız çekim koşulları altında kararlı (robust) öznitelik vektörleri üretebilmesinden kaynaklanmaktadır.



Şekil 4.1.4.1. SMPD Veri Setinden Seçilmiş Ham Görüntü Örnekleri

4.2. SIYAM AĞI MİMARİSİ VE METRİK ÖĞRENME (METRIC LEARNING)

Ödeme sistemleri gibi dinamik kullanıcı tabanına sahip uygulamalarda, sisteme her yeni müşteri eklendiğinde modelin baştan eğitilmesi operasyonel olarak mümkün değildir. Bu kısıtı aşmak amacıyla biyometrik doğrulama motoru olarak, tek seferlik öğrenme (one-shot learning) kapasitesine sahip Siyam Ağı (Siamese Network) mimarisi benimsenmiştir.

4.2.1. Tasarım Prensipleri ve Mimari Gerekçe


Siyam ağı, ağırlıkları ortak paylaşılan (shared weights) iki paralel sinir ağı dalından oluşur. Bu yapı sayesinde model, görüntüleri sabit bir sınıf etiketine atamak yerine yüksek boyutlu bir uzayda kimlik imzaları üretir ve iki imza arasındaki geometrik mesafeyi hesaplayarak doğrulama kararı verir. Modelin daha önce hiç görmediği bir bireyi de referans vektörü üzerinden doğrulayabilmesi, bu mimarinin en kritik avantajıdır.

Sisteme sunulan iki farklı avuç içi görüntüsü — kayıtlı referans ve anlık sorgu — aynı özellik çıkarıcı ağdan geçirilerek 512 boyutlu birer biyometrik kimlik vektörüne (embedding) dönüştürülür. Her iki dalın ağırlıklarının özdeş olması, matematiksel tutarlılık açısından zorunludur: aynı bireye ait iki görüntünün vektör uzayında aynı bölgeye düşmesi, ancak her iki dalın aynı dönüşüm fonksiyonunu uygulamasıyla garanti altına alınır.

MATERYAL VE METOT

Siyam Ağı Mimarisi

MobileNetV2 · ArcFace (m=0.50, s=64) · Kosinüs Benzerliği



Şekil 4.2.1 Siyam Ağı Mimarisi

4.2.2. Özellik Çıkarıcı (Encoder) ve Bottleneck Katmanı

Siyam ağının omurgası olarak MobileNetV2 mimarisi tercih edilmiştir. Bu tercih üç temel gerekçeye dayanmaktadır: uç cihazlarda düşük gecikme süresi sağlayan depthwise separable convolution yapısı, ImageNet üzerinde önceden eğitilmiş ağırlıkların doku tanıma kolayca uyarlanabilmesi ve rekabetçi doğruluk performansı sunan inverted residual blokların parametrik verimliliği.

MobileNetV2 omurgası 17 adet InvertedResidual bloğundan oluşur. Her blok, genişleme faktörü $t=6$ olan 1×1 expansion convolution, depthwise 3×3 convolution ve 1×1 projection convolution katmanlarını sırasıyla içerir. Omurganın çıkışında Global Average Pooling uygulanarak 1280 boyutlu bir özellik vektörü elde edilir. Bu vektör, ardından 512 nörona sahip tam bağlı (Dense) bir Bottleneck katmanına aktarılır ve Batch Normalization ile normalize edilir. Bottleneck katmanı, yüksek boyutlu omurga çıktısını daha kompakt ve ayırt edici bir temsile indirger; bu sayede hem hesaplama maliyeti azalır hem de aşağıda yer alan L2 Normalizasyon adımının etkinliği artar.

4.2.3. L2 Normalizasyon

Bottleneck katmanından çıkan 512 boyutlu vektör, ArcFace katmanına girmeden önce L2 Normalizasyona tabi tutulur. Bu işlem her vektörü birim hiperküre (unit hypersphere) yüzeyine yansıtır; yani vektörün büyüklüğünü 1'e eşitler ve yalnızca yönelim bilgisini korur:

$$\hat{e} = \frac{e}{\|e\|_2}$$

Bu adım kritik bir işlevsel zorunluluktur. Normalizasyon uygulanmadan, benzerlik skorları vektörlerin büyüklüğüne (magnitude) bağlı olarak sistematik biçimde sapabilir; yüksek aktivasyona sahip vektörler yapay olarak yüksek benzerlik skoru üretir. Normalizasyon sonrasında kosinüs benzerliği yalnızca vektörler arasındaki açısal ilişkiyi ölçer ve büyüklük etkisinden tamamen bağımsız hale gelir. Bu da sistemin farklı aydınlatma koşulları, çekim mesafesi ve kamera değişkenliği gibi görüntüsel gürültüye karşı direncini artırır.

4.2.4. ArcFace Açısal Marj Optimizasyonu

Klasik Siyam ağı uygulamalarında kullanılan Contrastive Loss ve Triplet Loss fonksiyonları, avuç içi gibi doku özellikleri açısından yüksek görsel benzerlik sergileyen sınıflarda ciddi bir darboğaz yaratır: farklı bireylere ait vektörler birbirinden yeterince ayrıştırılamaz ve benzerlik skorları 0.40–0.60 aralığında yığılır. Bu belirsiz bölge, yanlış kabul ve yanlış ret hatalarını birlikte yükseltir.

Bu sorunu gidermek amacıyla modele ArcFace (Additive Angular Margin) katmanı entegre edilmiştir. ArcFace, karar sınırını oluşturmak yerine her bir sınıfın merkezi ile hedef vektörü arasındaki açığa ek bir marj uygular:

$$\mathcal{L} = -\log \frac{e^{s \cdot \cos(\theta_{y_i} + m)}}{e^{s \cdot \cos(\theta_{y_i} + m)} + \sum_{j \neq y_i} e^{s \cdot \cos(\theta_j)}}$$

Projede kullanılan hiperparametre değerleri $m = 0.50$ (açısal marj) ve $s = 64.0$ (ölçek faktörü) olarak belirlenmiştir. Marj m , sınıflar arası ayrımı geometrik olarak sıkılaştırır; ölçek s ise gradyan akışını stabilize ederek eğitim dinamiklerini iyileştirir. Bu yapı sayesinde model, aynı bireye ait avuç içlerini vektör uzayında bir kümeye sıkıştırırken, farklı bireylere ait kümeleri açısal bir sınırla birbirinden uzaklaştıran kutuplaştırılmış (polarized) bir uzay oluşturur.

4.2.5. Mesafe Metrikleri ve Karar Mekanizması

Çıkarım (inference) aşamasında ArcFace katmanı devre dışı bırakılır. Yalnızca iki normalize vektör arasındaki kosinüs benzerliği hesaplanır:

$$\text{sim}(e_{\text{ref}}, e_{\text{qry}}) = \frac{e_{\text{ref}} \cdot e_{\text{qry}}}{\|e_{\text{ref}}\|_2 \cdot \|e_{\text{qry}}\|_2}$$

L2 Normalizasyon uygulandığından her iki vektörün büyüklüğü 1'e eşittir ve formül iç çarpıma (dot product) sadeleşir. Benzerlik skoru -1 ile $+1$ arasında değer alır; $+1$ tam örtüşmeyi, -1 tam zıtlığı temsil eder.

Eşik değeri, Eşit Hata Oranı (Equal Error Rate — EER) analizine dayanılarak 0.40 olarak belirlenmiştir. Bu noktada yanlış kabul oranı (FAR) ile yanlış ret oranı (FRR) birbirine eşitlenir ve sistem dengeli bir güvenlik-kullanılabilirlik dengesi yakalar. Buna göre karar kuralı şu şekilde işler:

- $\text{sim} > 0.40 \rightarrow$ Erişim Onaylandı (aynı birey)
- $\text{sim} \leq 0.40 \rightarrow$ Erişim Reddedildi (yetersiz benzerlik)

4.3. ÖZELLİK ÇIKARICI OMURGA (BACKBONE): MobileNetV2


Derin öğrenme tabanlı bir biyometrik sistemin başarısı, büyük ölçüde özellik çıkarıcı omurganın seçimine bağlıdır. Omurga, ham piksel verisini alarak biyometrik anlamlılık taşıyan yüksek seviyeli bir öznitelik temsiline dönüştüren katmanlar bütünüdür; sistemin "görmesini" sağlayan temel bileşendir. Bu çalışmada omurga seçimi, yalnızca doğruluk (accuracy) kriteri üzerinden değil; gecikme süresi (latency), bellek ayak izi (memory footprint) ve donanım uyumluluğu kriterleri birlikte değerlendirilerek yapılmıştır.

Başlangıç değerlendirmesinde literatürde yaygın biçimde tercih edilen ResNet-18 mimarisi aday olarak ele alınmıştır. Ancak gerçek zamanlı mobil doğrulama senaryosunun getirdiği kısıtlar, daha verimli bir omurga mimarisini zorunlu kılmıştır. Aşağıdaki alt bölümlerde önce ResNet-18 mimarisi katman düzeyinde incelenmekte, ardından MobileNetV2'nin yenilikçi blok yapıları ayrıntılı biçimde ele alınmakta ve iki mimari somut ölçütler üzerinden karşılaştırılmaktadır.

4.3.1. ResNet-18 Mimarisinin Katman Yapısı

ResNet (Residual Network), derin ağlardaki gradyan sönümlenmesi (vanishing gradient) sorununu "kısa yol bağlantısı" (shortcut connection) ile çözen ve He ve ark. (2016) tarafından önerilen bir mimari ailesidir. ResNet-18, bu ailenin en sık versiyonudur ve 18 ağırlıklı katman içerir.

Mimarinin temel yapı taşı, standart artık bloklardır (Residual Block). Her blok, giriş tensörünü iki paralel yoldan işler: birincil yol iki adet 3×3 standart evrişim katmanı ve Batch Normalization içerirken, kısa yol giriş tensörünü doğrudan bloğun çıkışına ekler. Bu toplama işlemi gradyan akışını derinlemesine sürdürür ve 18 katmana rağmen stabil eğitim sağlar. Ancak her 3×3 standart evrişim, giriş kanallarının tamamıyla tam matris çarpımı (full matrix multiplication) gerçekleştirir; bu da işlemsel yük açısından ciddi bir maliyet oluşturur.



Şekil 4.3.1 ResNet-18 katman yapısı ve standart evrişim maliyet analizi


Şekil 4.3.1'de görüldüğü üzere ResNet-18, giriş görüntüsünü 7×7 evrişimden sonra dört katman grubundan geçirmektedir. Her grupta kanal sayısı 64'ten 512'ye katlanır ve her artık blok içinde iki adet 3×3 standart evrişim uygulanır. Standart evrişimin hesaplama maliyeti $K \times K \times C_{in} \times C_{out}$ ile orantılı arttığından, 512 kanallı dördüncü katmana gelindiğinde tek bir piksel için uygulanan işlem sayısı yaklaşık 4.7 milyon çarpmaya ulaşmaktadır. Bu yük mobil cihazların işlemcisinde kabul edilemez gecikme (latency) süreleri oluşturmaktadır.

4.3.2. MobileNetV2 Mimarisi ve Yenilikçi Blok Yapıları

MobileNetV2, Sandler ve ark. (2018) tarafından önerilen ve uç cihaz dağıtımı (edge deployment) için optimize edilmiş hafif bir derin öğrenme mimarisidir. Mimarinin verimlilik avantajı iki temel yapısal yeniliğe dayanır.

Derinlemesine Ayrılabilir Evrişim (Depthwise Separable Convolution): Klasik evrişimi iki ardışık işleme böler. Birinci adımda her giriş kanalı yalnızca kendi 3×3 filtresiyle işlenir (depthwise convolution); kanallar arası hiçbir bilgi alışverişi gerçekleşmez. İkinci adımda 1×1 boyutlu noktasal evrişim (pointwise convolution) kanallar arası ilişkiyi öğrenir. Bu ayrıştırma, hesaplama maliyetini standart evrişime göre yaklaşık 8–9 kat düşürürken öznetelik çıkarım kapasitesini büyük ölçüde korur.

Ters Çevrilmiş Artık Blok (Inverted Residual Block): Klasik ResNet artık bloğu geniş kanalları önce daraltır, işler, sonra genişletir (wide $\rightarrow$ narrow $\rightarrow$ wide). MobileNetV2'nin inverted residual bloğu bu sırayı tersine çevirir: dar giriş genişletilir, depthwise evrişim ile işlenir, ardından tekrar daraltılır (narrow $\rightarrow$ wide $\rightarrow$ narrow). Genişletme faktörü (expansion factor) $t=6$ olarak ayarlanmıştır; bu, blok içi kanal sayısının giriş kanallarının 6 katına çıktığı anlamına gelir. Bu yapı, modelin avuç içi gibi ince dokusal örüntüleri blok içi yüksek boyutlu uzayda zengin biçimde temsil etmesini sağlar. Ayrıca kısa yol bağlantısı (residual connection) yalnızca dar kanallar arasında kurulur; bu da bellek kullanımını önemli ölçüde azaltır.




Şekil 4.3.2 MobileNetV2 tam katman yapısı ve Inverted Residual Blok iç mimarisi

Şekil 4.3.2, MobileNetV2'nin iki önemli özelliğini açıkça ortaya koymaktadır. Birincisi, inverted residual bloğun iç akışında kanal sayısı önce 6 kat genişletilmekte (expand), ardından depthwise evrişimle her kanal kendi filtresiyle bağımsız işlenmekte, son olarak 1×1 pointwise evrişimle tekrar daraltılmaktadır. İkincisi, kısa yol (residual) bağlantısı yalnızca stride=1 ve giriş-çıkış kanal boyutları eşit olduğunda aktif hale gelmekte; bu durum hem gradyan akışını stabilize etmekte hem de bellek kullanımını minimize etmektedir.

4.3.3. Mimari Karşılaştırma: ResNet-18 ve MobileNetV2

İki mimarinin temel tasarım tercihleri ve ölçülebilir çıktıları aşağıda karşılaştırmalı olarak sunulmaktadır.



Şekil 4.3.3 ResNet-18 ve MobileNetV2 mimari karşılaştırması

4.3.4. Neden ResNet Değil, MobileNetV2?

Omurga seçimi yalnızca doğruluk puanına bakılarak yapılan akademik bir tercih değil; sistemin gerçek dünya operasyonel kısıtları altında çalışabilirliğini doğrudan belirleyen mühendislik kararıdır. Aşağıda dört temel gerekçe ayrıntılı biçimde sunulmaktadır.

4.3.4.1. Gerçek Zamanlı Gecikme Kısıtı

Mobil ödeme sistemlerinde biyometrik doğrulama, kullanıcının ödeme akışını kesintisiz tamamlayabilmesi için 1 saniyenin altında tamamlanmalıdır. Yapılan karşılaştırmalı testlerde ResNet-18, orta düzey akıllı telefon işlemcisinde (Snapdragon 680 sınıfı CPU) tek bir görüntü için ortalama 320 ms gecikme üretmiştir. Bu süre; görüntü ön işleme (~40 ms) ve kosinüs benzerliği hesabı (~5 ms) ile birlikte toplamda 365 ms'yi aşmakta, dolayısıyla kullanıcı deneyimini olumsuz etkilemektedir. MobileNetV2 aynı donanımda 25 ms ile yanıt vermekte; uçtan uca toplam gecikme 70 ms'nin altında kalmaktadır.

4.3.4.2. Bellek Ayak İzi ve TFLite Dönüşümü

ResNet-18, TFLite formatına dönüştürüldüğünde yaklaşık 45 MB disk alanı kaplamaktadır. Akıllı telefon uygulamalarının bant genişliği kısıtları ve kullanıcı kabul eşikleri göz önüne alındığında bu boyut, uygulama yükleme süresini ve güncelleme maliyetini olumsuz etkiler. MobileNetV2 tabanlı model ise 13 MB'a inerek kurulum paketi içinde ihmal edilebilir bir yer kaplar. Ayrıca düşük parametre sayısı (~3.4M), çalışma zamanı RAM kullanımını azaltarak diğer uygulama bileşenlerinin yavaşlamasını engeller.

4.3.4.3. Biyometrik Doku Temsili Yeterliliği

MobileNetV2'nin depthwise convolution yapısı, bir özneliğin yalnızca kendi kanalında işlenmesini sağlar; bu durum avuç içi gibi lokal ve tekrarlı doku örüntülerini temsil etmede beklenmedik bir avantaj yaratmaktadır. Avuç içi dokusunun temel biyometrik içeriği olan palmak çizgileri, papiller hatlar ve deri kıvrımları; lokal, yönlü ve tekrarlayan yapılar içerir. Depthwise convolution, bu lokal özellikleri kanal bazında bağımsız biçimde kodlarken kanallar arası ilişkiyi pointwise convolution ile öğrenir. Yapılan deneylerde MobileNetV2 tabanlı siyam ağının, eğitim seti üzerinde ResNet-18 tabanlı muadiliyle eşdeğer ve bazı konfigürasyonlarda daha kararlı (lower variance) doğrulama performansı ürettiği gözlemlenmiştir.

4.3.4.4. Transfer Öğrenme Uyumluluğu

MobileNetV2, ImageNet üzerinde 1.2 milyon görüntüyle ön eğitilmiş ağırlıklarla birlikte sunulmakta ve TensorFlow Hub üzerinden doğrudan erişilebilmektedir. Bu ağırlıklar; kenar, doku, renk geçişi ve yüzey yapısı gibi düşük seviyeli görsel özellikleri kodlamaktadır. Avuç içi doku tanıma görevi bu düşük seviyeli özelliklerle yüksek örtüşme sergilediğinden, transfer öğrenme (fine-tuning) süreci ResNet'e kıyasla daha az eğitim verisi ve daha az epoch ile yüksek performansa ulaşmaktadır.

Bu dört gerekçenin bütünleşik değerlendirmesi sonucunda MobileNetV2, sistemin omurgası olarak seçilmiştir. ResNet-18 daha derin ve daha büyük bir model olmasına karşın, gerçek zamanlı mobil doğrulama senaryosunun getirdiği gecikme, bellek ve dağıtım kısıtları altında operasyonel olarak uygulanabilir değildir. MobileNetV2 ise bu kısıtları karşılarken biyometrik öznelik çıkarma kapasitesinden anlamlı bir taviz vermemektedir. Doğruluk ile verimlilik arasındaki bu denge, sistemin üretim ortamındaki sürdürülebilirliği açısından belirleyici öneme sahiptir.

4.4. TFLite DAĞITIM MİMARİSİ

Geliştirilen biyometrik doğrulama modelinin mobil cihazlarda çalışabilmesi için PyTorch formatındaki model ağırlıklarının, mobil çıkarım çerçevesi olan TensorFlow Lite (TFLite) formatına dönüştürülmesi gerekmektedir. Bu dönüşüm doğrudan mümkün olmadığından, iki aşamalı bir köprü mimarisi uygulanmıştır: önce PyTorch'tan ONNX (Open Neural Network Exchange) formatına, ardından ONNX'ten TFLite formatına geçiş yapılmıştır.

4.4.1. ArcFace Katmanının Çıkarılması ve Embedding Sarmalayıcı

Eğitim sürecinde model iki bileşenden oluşmaktadır: özellik çıkarıcı encoder ve eğitim kaybını hesaplayan ArcFace head. Çıkarım (inference) aşamasında ArcFace katmanına ihtiyaç yoktur; yalnızca 512 boyutlu embedding vektörünü üreten encoder kısmı mobil uygulamaya aktarılmaktadır. Bu amaçla orijinal ArcFaceModeli sınıfı bir sarmalayıcı (EmbeddingModeli) içine alınarak forward() metodunun yalnızca embedding_cikart() fonksiyonunu çağırması sağlanmıştır. Bu sayede export edilen model yalnızca [1, 224, 224, 3] boyutunda bir giriş tensörü olarak [1, 512] boyutunda L2 normalize edilmiş bir embedding vektörü üretmektedir.

4.4.2. PyTorch → ONNX Dönüşümü

ONNX, farklı derin öğrenme çerçeveleri arasında model taşınabilirliği sağlayan açık bir ara format standardıdır. torch.onnx.export() fonksiyonu ile model opset versiyonu 11 olarak ONNX formatına aktarılmıştır. Batch boyutunun dinamik bırakılması (dynamic_axes), ileride toplu çıkarım senaryolarına esneklik kazandırmaktadır. Dönüşüm sonrasında onnxsim kütüphanesi ile model sadeleştirme (simplification) uygulanmış; gereksiz operatörler ve sabit katlanma (constant folding) optimizasyonları gerçekleştirilmiştir.

4.4.3. ONNX → TFLite Dönüşümü ve Doğrulama

onnx2tf kütüphanesi aracılığıyla sadeleştirilmiş ONNX modeli TensorFlow SavedModel formatına, ardından otomatik olarak TFLite formatına dönüştürülmüştür. Dönüşüm sonrasında TFLite Interpreter ile doğrulama yapılmış; rastgele [1, 224, 224, 3] float32 tensörü ile çıkarım gerçekleştirilerek [1, 512] boyutunda çıktı elde edildiği teyit edilmiştir. Nihai model ~13 MB boyutuna ulaşmış olup bu boyut, standart mobil uygulama bant genişliği kısıtları açısından kabul edilebilir sınırlardadır.

Mobil uygulamada giriş görüntüsü modele verilmeden önce piksel değerleri [0, 1] aralığına normalize edilmekte, ardından ImageNet istatistikleriyle standardize edilmektedir. Bu adım, modelin eğitim sırasında kullandığı torchvision.transforms.Normalize işlemine karşılık gelmekte olup normalizasyon atlandığında embedding kalitesi belirgin biçimde düşmektedir.

4.5. MOBİL UYGULAMA MİMARİSİ

Geliştirilen biyometrik ödeme sistemi, Flutter SDK üzerinde inşa edilmiş çok katmanlı bir mobil uygulama mimarisine sahiptir. Uygulama; görüntü yakalama, model çıkarımı, biyometrik kayıt ve doğrulama işlevlerini birbirinden bağımsız servis katmanlarında yönetmektedir.



4.5.1. Görüntü Yakalama ve TFLite Çıkarım Pipeline'i

CameraService, uygulamanın biyometrik özellik çıkarma motorudur. Kayıt aşamasında kullanıcıdan 5 farklı açıda görüntü alınmakta; her görüntü için hem normal hem de yatay çevrilmiş (flipHorizontal) versiyonu modele girilerek 10 adet embedding vektörü elde edilmektedir. Bu yaklaşım, eğitim verilerindeki sağ el ve sol el varyasyonuna karşı sistem dayanıklılığını artırmaktadır.

Her görüntü modele verilmeden önce üç adımlı ön işlemden geçmektedir: görüntü image paketi ile merkez kare kırpma yöntemiyle kare hale getirilmekte, ardından 224×224 piksel boyutuna yeniden ölçeklenmekte, son olarak piksel değerleri ImageNet normalizasyon istatistikleriyle standardize edilmektedir. Normalize edilen [1, 224, 224, 3] boyutundaki float32 tensörü TFLite Interpreter'a beslenerek [1, 512] boyutunda L2 normalize edilmiş embedding vektörü elde edilmektedir.

4.5.2. Biyometrik Kayıt Mekanizması

Kayıt sürecinde elde edilen birden fazla embedding vektörü bileşen bazında ortalaması alınarak tek bir temsil vektörüne indirgenmektedir:

$$\bar{e}[i] = \frac{1}{N} \sum_{j=1}^N e_j[i], \quad i = 0, 1, \dots, 511$$

Bu ortalama vektör, JSON formatında serileştirilmekte ve SQLite veritabanında (palmpay.db) kullanıcı kaydıyla birlikte saklanmaktadır. PIN güvenliği için SHA-256 hash fonksiyonu kullanılmakta; PIN hiçbir zaman düz metin olarak depolanmamaktadır.

4.5.3. Cosine Benzerlik Tabanlı Doğrulama Kararı

Doğrulama aşamasında anlık görüntüden çıkarılan embedding vektörü, veritabanındaki kayıtlı referans vektörüyle kosinüs benzerliği hesabı üzerinden karşılaştırılmaktadır:

$$\text{sim}(e_{\text{ref}}, e_{\text{qry}}) = \frac{e_{\text{ref}} \cdot e_{\text{qry}}}{\|e_{\text{ref}}\|_2 \cdot \|e_{\text{qry}}\|_2}$$

Benzerlik skoru, SharedPreferences üzerinde saklanan ve varsayılan değeri 0.60 olan eşik değeriyle karşılaştırılarak erişim kararı verilmektedir. Bu eşik değeri, kullanıcı tarafından uygulama ayarlarından 0.40–0.95 arasında ayarlanabilmektedir. Üç başarısız denemeden sonra PIN yedek doğrulaması otomatik olarak devreye girmektedir.

DENEYSEL ÇALIŞMALAR


Bu bölümde, önceki kısımlarda teorik altyapısı sunulan biyometrik doğrulama sisteminin deneysel test aşamaları, veri optimizasyon süreçleri ve model eğitim dinamikleri detaylandırılmıştır. Tüm deneysel süreçler, izlenebilirlik ve tekrarlanabilirlik ilkesi gereği modüler bir yapı (Modül 1: Ön İşleme ve Modül 2: Model Eğitimi) halinde yürütülmüş; elde edilen sayısal ve görsel çıktılar aşağıda analiz edilmiştir.

5.1. ADAPTİF ROI MOTORU VE GÖRÜNTÜ KALİE (QA) OPTİMİZASYONU

Kısıtlamasız veri setindeki (SMPD) çevresel gürültüleri filtrelemek amacıyla Modül 1 kapsamında geliştirilen Adaptif ROI Motoru, deneysel olarak test edilmiştir. Sistemin biyometrik girdiyi hazırlama süreci şu ardışık algoritmalarla yürütülmüştür:

5.1.1. HSV Segmentasyon ve Kütle Merkezi (Centroid) Tespiti

MediaPipe'in anatomik noktaları bulamadığı zorlu görüntülerde sistem, geri dönüş (fallback) mekanizması olarak HSV renk uzayına geçiş yapmıştır. Deri piksellerini izole eden maskeleme işlemi sonrasında, elde edilen konturların görüntüsel momentleri (cv2.moments) hesaplanmıştır. Avuç içinin geometrik ağırlık merkezi (Centroid), $C_x = M_{10}/M_{00}$ ve $C_y = M_{01}/M_{00}$ formülasyonu ile tespit edilerek, elin duruş açısından bağımsız 224x224 piksellik kesin (crisp) bir kırpma işlemi gerçekleştirilmiştir.



Yapılan deneysel testlerde, algoritmanın farklı poz tiplerindeki (F, RF, P, RP) kısıtlamasız el görüntülerini işleme yeteneği test edilmiştir. Sistemin rastgele seçilen örnekler üzerindeki başarısı ve HSV-Centroid geri dönüş (fallback) mekanizmasının kırpma kalitesi Şekil 5.1.1.1'de görselleştirilmiştir.

Şekil 5.1.1.1. Adaptif ROI Motorunun farklı poz ve ışık koşullarındaki test sonuçları. Sol sütun: Kısıtlamasız ham görüntüler, Sağ sütun: HSV-Centroid tabanlı algoritmalarla hizalanmış 224x224 RGB biyometrik çıktılar.

ROI Motoru Başarım Analizi: Geliştirilen boru hattının (pipeline) yapısal kararlılığını ölçmek amacıyla AvuciciROIExtractor sınıfı üzerinden oluşturulan test modülünün konsol çıktıları aşağıda sunulmuştur. Sistem, farklı zorluk derecelerine sahip rastgele örneklem setinde hedef bölgeyi başarıyla izole etmiştir:

Sonuç: 12/12 başarılı (%100)				
Poz	Kişi	Dosya	Yöntem	Durum
F	032	032_F_0.JPG	hsv_centroid	✓
F	026	026_F_8.JPG	hsv_centroid	✓
F	072	072_F_4.JPG	izgara_kirp	✓
P	001	001_P_22.JPG	hsv_centroid	✓
P	057	057_P_29.JPG	hsv_centroid	✓
P	073	073_P_21.JPG	hsv_centroid	✓
RF	023	023_RF_18.JPG	izgara_kirp	✓
RF	011	011_RF_17.JPG	hsv_centroid	✓
RF	007	007_RF_16.JPG	hsv_centroid	✓
RP	005	005_RP_36.JPG	hsv_centroid	✓
RP	071	071_RP_31.JPG	hsv_centroid	✓
RP	076	076_RP_32.JPG	hsv_centroid	✓

Şekil 5.1.1.2. Adaptif ROI Motoru test modülü konsol çıktısı. Farklı çekim açılarından (F, P, RF, RP) rastgele seçilen örneklemelerde, geliştirilen algoritmaların (HSV-Centroid ve Izgara Kırpma) koordineli çalışmasıyla elde edilen %100'lük (12/12) biyometrik kırpma başarısı.

5.1.2. CLAHE ve Fotometrik Testler

Kontrast sınırlamalı adaptif histogram eşitleme (CLAHE) algoritması, avuç içi çizgilerini belirginleştirmek amacıyla test edilmiştir. Deneysel çıktılar, bu işlemin kılcal çizgileri ortaya çıkardığını ancak aşırı uygulandığında (yüksek clip_limit) RGB uzayında gürültü amplifikasyonuna yol açtığını göstermiştir.


5.1.3. Kalite Filtresi (QA Filter - %50 Kuralı)

Modelin hatalı öğrenmesini (false-learning) engellemek için, elde edilen ROI karesi içindeki deri pikseli yoğunluğu ölçülmüştür. Ten rengi oranı %50'nin altında kalan (aşırı karanlık veya arka planın baskın olduğu) görüntüler sistemden otomatik olarak reddedilmiş (drop) ve model eğitimine dahil edilmemiştir.

5.1.4. MediaPipe ve Adaptif HSV (Fallback) Mekanizmasının Karşılaştırmalı Analizi

Kısıtlanmasız (unconstrained) mobil veri setlerinin en büyük zorluğu; elin kameraya olan açısının, ortam ışığının ve arka plan karmaşasının standart algoritmaları yanıltmasıdır. Geliştirme sürecinde sisteme entegre edilen MediaPipe Vision Tasks (Hand Landmarker) modelinin, özellikle düşük ışııkta veya elin kadrja tam sığmadığı durumlarda el iskeletini çıkarmakta başarısız olduğu (drop-out) tespit edilmiştir.

Bu zafiyeti gidermek amacıyla kurgulanan Adaptif HSV-Centroid Yedekleme (Fallback) mekanizmasının başarısını ölçmek için rastgele seçilen görüntüler üzerinde karşılaştırmalı bir deney yürütülmüştür.



Şekil 5.1.4.1. Zorlu çekim koşullarında MediaPipe (Hand Landmarker) algoritmasının başarısız olduğu durumlarda, geliştirilen Adaptif HSV-Centroid mekanizmasının biyometrik ROI kırpma başarısı.

DENEYSEL ÇALIŞMALAR

Şekil 5.1.4.1' de sunulan örneklerde görüldüğü üzere; gölge düşmesi, cilt tonu yansımaları veya parmak boğumlarının kadraj dışında kalması gibi durumlarda MediaPipe algoritması elin merkezini bulamayarak "BAŞARISIZ" durumuna düşmüştür. Ancak geliştirilen çok katmanlı HSV maskeleme ve görüntü momentleri (m_{10}/m_{00}) tabanlı algoritma, aynı görüntülerde devreye girerek avuç içi "çekirdek" (Core Palm) bölgesini 224x224 RGB formatında kayıpsız bir şekilde izole etmeyi başarmıştır.

Test veri seti üzerinden koşturulan Python test modülünün konsol çıktıları (log) bu durumu sayısal olarak da doğrulamaktadır:

```
Karşılaştırma Özeti (12 görüntü):
MediaPipe : 3/12 (%25)
HSV       : 12/12 (%100)
```

Poz	Kişi	Dosya	MP	HSV
F	038	038_F_9.JPG	✗	✓
F	009	009_F_1.JPG	✓	✓
F	074	074_F_8.JPG	✗	✓
P	025	025_P_24.JPG	✓	✓
P	047	047_P_29.JPG	✗	✓
P	046	046_P_21.JPG	✗	✓
RF	024	024_RF_16.JPG	✗	✓
RF	036	036_RF_12.JPG	✗	✓
RF	003	003_RF_17.JPG	✗	✓
RP	068	068_RP_31.JPG	✗	✓
RP	070	070_RP_37.JPG	✓	✓
RP	090	090_RP_39.JPG	✗	✓

Şekil 5.1.4.2. MediaPipe ve Adaptif HSV (Yedekleme) mekanizmalarının karşılaştırmalı başarımların analizi. Kısıtlamasız ortamın yarattığı zorluklar nedeniyle MediaPipe tespitinin %25 başarıda kaldığı (drop-out) aynı senaryolarda; geliştirilen HSV motorunun hata telafisi yaparak veri kaybını sıfıra indirdiği (%100 başarı) görülmektedir.

Bu deneysel kanıt, sistemin sadece ideal koşullarda değil, mobil kullanıcıların yaratabileceği her türlü kötü senaryoda bile modeli besleyecek kaliteli biyometrik girdiyi (ROI) üretebildiğini ve veri kaybını (data loss) sıfıra indirdiğini göstermektedir.

DENEYSEL ÇALIŞMALAR

	A	B	C	D	E	F
1	Kisi_id	poz_tipi	dosya_adi	yontem	kalite_skoru	durum
2		1 F	001_F_0.JPG	hsv_centroid	0.74	basarili
3		1 F	001_F_1.JPG	hsv_centroid	0.706	basarili
4		1 F	001_F_2.JPG	hsv_centroid	0.711	basarili
5		1 F	001_F_3.JPG	hsv_centroid	0.755	basarili
6		1 F	001_F_4.JPG	hsv_centroid	0.75	basarili
7		1 F	001_F_5.JPG	hsv_centroid	0.755	basarili
8		1 F	001_F_6.JPG	hsv_centroid	0.749	basarili
9		1 F	001_F_7.JPG	hsv_centroid	0.779	basarili
10		1 F	001_F_8.JPG	hsv_centroid	0.804	basarili
11		1 F	001_F_9.JPG	hsv_centroid	0.747	basarili
12		1 P	001_P_20.JPG	hsv_centroid	0.84	basarili
13		1 P	001_P_21.JPG	hsv_centroid	0.84	basarili
14		1 P	001_P_22.JPG	hsv_centroid	0.833	basarili
15		1 P	001_P_23.JPG	hsv_centroid	0.833	basarili
16		1 P	001_P_24.JPG	hsv_centroid	0.833	basarili
17		1 P	001_P_25.JPG	hsv_centroid	0.833	basarili
18		1 P	001_P_26.JPG	hsv_centroid	0.82	basarili
19		1 P	001_P_27.JPG	hsv_centroid	0.82	basarili
20		1 P	001_P_28.JPG	hsv_centroid	0.82	basarili
21		1 P	001_P_29.JPG	hsv_centroid	0.82	basarili
22		1 RF	001_RF_10.JPG	hsv_centroid	0.796	basarili
23		1 RF	001_RF_11.JPG	hsv_centroid	0.796	basarili

Şekil 5.1.5.2. ROI Motoru tarafından her bir görüntü için hesaplanan biyometrik kalite skorları (QA) ve otomatik ayıklama (drop) kararlarını içeren sistem log kayıtları.

(Bölüm 4'te bahsedilen 2.916 sayısı, bu 3.426 kullanılabilir görüntü içinden biyometrik değeri olmayan el sırtı -F ve RF- pozlarının da elenmesiyle ulaşılan nihai avuç içi sayısını temsil etmektedir.)

5.1.6. Biyometrik Kalite (QA) Sınırlarının Belirlenmesi ve Veri İzolasyonu


Toplu işleme sonucunda elde edilen ROI'lerin eğitim seti için yeterliliğini belirlemek amacıyla, sistemin hesapladığı "Cilt Pikseli Yoğunluk Skoru (QA Score)" üzerinden istatistiksel bir eşik (threshold) analizi yürütülmüştür.

Eğitim setini gürültüden (noise) arındırmak ve Siyam ağının hatalı çizgileri öğrenmesini (false-learning) engellemek için, Şekil 5.1.6.1'de sunulan görsel analizler sonucunda optimum kabul eşığı $QA \geq 0.50$ olarak belirlenmiştir. Bu eşığın altındaki görüntüler aşırı karanlık, hareket bulanıklığı (motion blur) barındıran veya arka planın avuç içini kapattığı geçersiz örneklemelerdir.



Şekil 5.1.6.1. Farklı cilt kalite (QA) aralıklarına düşen ROI örneklemelerinin görsel matrisi. Sistemin kabul ve ret kararını nasıl verdiğini (eşik: 0.50) göstermektedir.

Söz konusu eşik değerine bağlı olarak yapılan optimizasyonlar sonucunda veri setindeki bazı bireylerin (Subject ID) geçerli görüntü sayısının 10'un altına düştüğü saptanmıştır. Siyam ağının tekil kullanıcı başına yeterli veriyle eğitilebilmesi için ['030', '058', '081', '085', '090'] numaralı kullanıcılar (outliers) sistemden tamamen izole edilmiştir.




Şekil 5.1.6.2. Biyometrik optimizasyonlar ve minimum görüntü kısıtı (min=10) sonrası oluşturulan "Nihai Veri Seti (v2)" modül raporu. Veriler model eğitimi öncesi %70 Eğitim (60 Kişi), %15 Doğrulama (12 Kişi) ve %15 Test (14 Kişi) olacak şekilde kimlik (ID) bazlı olarak sızıntısız biçimde bölünmüştür.

5.2. İKİ FAZLI (TWO-PHASE) MODEL EĞİTİMİ VE HİPERPARAMETRE OPTİMİZASYONU

Derin öznitelik çıkarıcı omurga olan MobileNetV2'nin ImageNet üzerinde öğrendiği genel geçer doku özelliklerini, rastgele ilklendirilmiş (random initialized) ArcFace ağırlıklarının yaratacağı yıkıcı gradyanlardan korumak amacıyla İki Fazlı Transfer Öğrenme (Two-Phase Transfer Learning) stratejisi uygulanmıştır.

Model (yaklaşık 3.4 Milyon parametre), dinamik öğrenme oranı planlayıcısı (StepLR) ve Erken Durdurma (Early Stopping) mekanizmalarıyla eğitilmiştir.

- **Faz 1 (Isınma - Epoch 1-10):** Ağa ait MobileNetV2 evrimsel omurgası tamamen dondurulmuş (frozen) ve öğrenme oranı $1 \cdot 10^{-3}$ olarak ayarlanmıştır. Bu fazda yalnızca 512 boyutlu yeni Embedding Bottleneck katmanı ve ArcFace sınıf ağırlıkları eğitilerek ağın biyometrik uzaya "ısınması" sağlanmıştır.
- **Faz 2 (İnce Ayar / Fine-Tuning - Epoch 11-43):** Omurga kilitleri açılarak tüm model eğitime dahil edilmiştir. Hassas doku filtrelerini bozmamak (catastrophic forgetting engellemek) için öğrenme oranı $1 \cdot 10^{-4}$ seviyesine düşürülmüştür.



Şekil 5.2.1. MobileNetV2 ve ArcFace entegrasyonuna ait iki fazlı eğitim süreci grafikleri (Kayıp, Doğrulama Başarımı ve Öğrenme Oranı değişimi). Faz 2'ye geçişle (Epoch 11) birlikte doğruluk oranındaki logaritmik sıçrama açıkça görülmektedir.

Eğitim, validation kaybının iyileşmeyi durdurduğu 43. Epoch'ta Early Stopping mekanizması tarafından otomatik olarak kesilmiş ve modelin ezberlemesi (overfitting) engellenmiştir. Süreç sonunda ulaşılan Maksimum Doğrulama Başarımı (Validation Accuracy) %95.25 olarak kaydedilmiştir.


5.3. ArcFace KUTUPLAŞTIRMA ANALİZİ VE EŞİK (Threshold) BELİRLEME

Siyam ağı doğrulama motorunun kalbi olan 512 boyutlu vektörlerin (embeddings) uzaysal dağılımını ölçmek için test veri seti üzerinde (modelin daha önce hiç görmediği 496 görüntü) Kosinüs Benzerliği analizi yapılmıştır.

ArcFace katmanının uyguladığı açısız marj ($m=0.50$) sayesinde, öznitelik uzayının ne kadar başarılı bir şekilde kutuplaştırıldığı (polarized) şu sonuçlarla ispatlanmıştır:

- Aynı kişiye ait avuç içlerinin ortalama benzerliği: 0.475
- Farklı kişilere ait avuç içlerinin ortalama benzerliği: 0.020

İki sınıf arasındaki bu devasa uçurum, sistemin sahte kabulleri (FAR) ve sahte retleri (FRR) dengeleyebilmesi için ideal bir zemin sunmuştur. Sistem için optimum karar eşiği, Eşit Hata Oranının (Equal Error Rate - EER) sağlandığı nokta olan 0.224 olarak hesaplanmıştır.



Eşik	FAR	FRR	Doğruluk
0.20	26.2%	19.3%	74.25%
0.25	19.4%	25.0%	80.25%
0.30	14.4%	31.4%	84.40%
0.22	22.8%	22.9%	77.20% ← EER
0.40	5.8%	48.6%	91.25%
0.45	3.1%	57.9%	93.10%
0.50	1.7%	63.6%	93.95%

Şekil 5.3.1. Test veri seti üzerinde hesaplanan ROC Eğrisi (EER: %22.8) ve kosinüs benzerliği frekans dağılımı. Aynı ve farklı kimliklere ait vektörlerin kesişim noktasında, üretim ortamı (production) erişim onayı için eşik değeri 0.224 olarak saptanmıştır. (Bu eşiğe göre; sistemin ürettiği benzerlik skoru 0.224'ün üzerindeyse kişi onaylanacak, altındaysa reddedilecektir.)

5.4. UÇ BİLİŞİM (EDGE AI) DERLEMESİ VE DONANIM OPTİMİZASYONU

Projenin temel amacı, avuç içi doğrulama sisteminin herhangi bir bulut sunucusuna (API) ihtiyaç duymadan, doğrudan kullanıcının mobil cihazında (Offline/On-Device) çalışabilmesidir.




Eğitimleri tamamlanan ve .pth (PyTorch) formatında 13.6 MB yer kaplayan model, doğrudan mobil cihazlarda çalıştırılamayacağı için bir dönüştürme ve budama (pruning) işlemine tabi tutulmuştur:

- **ArcFace Katmanının Ayrılması:** Eğitim sırasında 60 farklı sınıfı ayırt etmek için kullanılan ağır ArcFace başlığı (head) modelden kesilip atılmış, geriye sadece saf girdi alıp 512 boyutlu vektör (imza) üreten hafif özellik çıkarıcı omurga bırakılmıştır.
- **ONNX ve TFLite Dönüşümü:** Model, platform bağımsız çalışabilmesi için önce ONNX formatına, ardından donanım hızlandırma (NNAPI/GPU Delegate) destekli TensorFlow Lite (.tflite) formatına derlenmiştir.

Derleme işlemleri sonucunda, girdi şekli [1, 224, 224, 3] ve çıktı şekli [1, 512] olan 13 MB boyutunda, Edge-AI standartlarına tam uyumlu ve mobil cihazların RAM/CPU kısıtlamalarını zorlamayacak nihai bir biyometrik yapay zeka çekirdeği elde edilmiştir.

6.1 ONBOARDING (İLK AÇILIŞ)

PalmPay uygulaması ilk açıldığında kullanıcıyı üç aşamalı bir karşılama akışıyla karşılar: yasal onay, uygulama tanıtımı ve izin yönetimi. Bu akış; kullanıcıyı uygulamaya alıştırmayı, gerekli yasal gereklilikleri karşılamayı ve kamera iznini güven odaklı bir şekilde talep etmeyi amaçlamaktadır.




Uygulama ilk açıldığında kullanıcıya KVKK kapsamındaki veri işleme politikası sunulur. Bu ekranda dört madde listelenir: verilerin yalnızca cihazda saklandığı, kamera görüntülerinin üçüncü taraflarla paylaşılmadığı, verilerin silinebildiği ve işlemlerin KVKK'ya uygun olduğu. "Kabul Ediyorum" butonu, her iki onay kutusu işaretlenmeden aktif hale gelmez.


Ekran aşağı kaydırıldığında Kullanım Koşulları ve Gizlilik Politikası onay kutuları görünür hale gelir. İki kutunun da işaretlenmesi zorunludur; bu tasarım tercihi kullanıcının her iki belgeyi de bilinçli olarak kabul etmesini sağlar.

Her iki onay kutusu işaretlendiğinde "Kabul Ediyorum" butonu mor renge dönerek aktif hale gelir. Buton üzerindeki kilit ikonu, onay verilmeden ilerlemenin mümkün olmadığını görsel olarak da pekiştirir.

ARAYÜZ TANITIMI



Onay sonrasında uygulama, üç slayttan oluşan bir tanıtım akışı sunar. İlk slayt uygulamanın temel işlevini tanıtır: avuç içi damar iziyle temassız ödeme. İkinci slayt güvenlik vurgusunu ön plana çıkarır; biyometrik verinin şifreli biçimde yalnızca cihazda saklandığı belirtilir. Üçüncü slayt kullanıcıyı kayıt olmaya yönlendiren harekete geçirici bir ekranla akışı tamamlar. Sağ altta yer alan ok butonu ile ilerlenebilir; son ekranda "Kayıt Ol" ve "Ana Sayfaya Git" olmak üzere iki seçenek sunulur.



Kullanıcı kayıt akışına girdiğinde uygulama, kamera iznini talep etmeden önce kendi izin bilgilendirme ekranını gösterir. Bu ekranda görüntülerin cihazda işlendiği ve hiçbir yere gönderilmediği açıkça belirtilir. Bu ara ekran, sistem izninden önce kullanıcıya bağlam sunarak güveni artırmayı hedefler.

Ardından iOS'un standart kamera izin diyalogu açılır. Kullanıcıya üç seçenek sunulur: uygulamayı kullanırken izin vermek, yalnızca bu sefer izin vermek veya izin vermemek. Uygulama, kamera erişimi olmadan çalışmadığından bu adım kayıt akışının zorunlu bir parçasıdır.

6.2 ANA EKRAN

Ana ekran, PalmPay'in tüm işlevlerine tek bir görünümünden erişim sağlayan merkezi arayüzdür. Koyu tema üzerine kurulu minimalist tasarımıyla kullanıcıyı yalnızca temel işlemlere yönlendirir.

Ana Ekran Bileşenleri

- | | |
|---|--|
| 1 Uygulama logosu ve başlığı | 5 Kullanıcılar — kayıtlı kişiler listesi |
| 2 Kullanıcı yönetimi ve uygulama ayarları | 6 Geçmiş — tüm ödeme kayıtları |
| 3 Ödeme Yap — ana işlev butonu | 7 Marka sloganı — Güvenli • Hızlı • Temassız |
| 4 Kayıt Ol — yeni kullanıcı ekleme | |

① Uygulama logosu ve başlığı: Ekranın sol üst köşesinde PalmPay logosu ve uygulama adı yer alır. Başlığın altındaki "Avuç içi biyometrik ödeme sistemi" ifadesi uygulamanın işlevini tek cümleyle tanımlar.


③ Ödeme Yap: Ekranın merkezini kaplayan büyük mor kart, uygulamanın birincil işlevini temsil eder. Kullanıcı bu karta dokunduğunda kamera açılarak avuç tarama süreci başlar.

④ Kayıt Ol: Yeni bir kullanıcının avuç izini sisteme eklemek için kullanılan giriş noktasıdır.

⑦ Güvenli • Hızlı • Temassız: Uygulamanın değer önerisini özetleyen slogan, ekranın alt kısmında sabit olarak yer alır.

② Kullanıcı yönetimi ve ayarlar: Sağ üst köşede iki ikon bulunur. İlki kayıtlı kullanıcı profillerine, ikincisi uygulama ayarlarına erişimi sağlar.

⑥ Geçmiş: Gerçekleştirilmiş tüm ödeme işlemlerinin kronolojik kaydına erişimi sağlar.



⑤ Kullanıcılar: Daha önce kaydedilmiş kişilerin listesini görüntüler; var olan kayıtları yönetmeye olanak tanır.

Ana ekran tasarımı, hiyerarşik bir öncelik anlayışıyla kurgulanmıştır: en sık kullanılan işlev (ödeme yapma) en büyük ve merkezi alanda konumlandırılmış; yönetim işlevleri ise ikincil konumlarda tutulmuştur.

6.3 KULLANICI KAYDI EKRANI


Kullanıcı kaydı, avuç izi verisinin sisteme ilk kez işlendiği adımdır. Kayıt süreci iki aşamadan oluşur:

- beş farklı açıdan avuç tarama
- ardından 6 haneli güvenlik PIN'i oluşturma.

Tüm veri işleme cihaz üzerinde gerçekleşir.

6.3.1 Avuç Tarama Ekranı





Kayıt ekranı, canlı kamera görüntüsü üzerine bindirilen bir arayüz olarak tasarlanmıştır. Kullanıcı sol veya sağ el seçimini yapar, ismini girer ve ardından beş farklı pozisyonda avucunu taratır. Her tarama sonrasında tamamlanan pozisyon yeşil tike dönüşür; bir sonraki pozisyon için dinamik bir talimat metni gösterilir.



Avuç Kaydı Ekranı Bileşenleri

- | | |
|--|--|
| 1 Geri butonu — bir önceki ekrana dönüş | 6 Kullanıcı ismi giriş alanı |
| 2 Ekran başlığı — "Avuç Kaydı" | 7 Anlık yön talimatı (dinamik güncellenir) |
| 3 Flaş / El feneri kontrolü | 8 5 pozisyon göstergesi (Düz, Sol, Sağ, Yakın, Uzak) |
| 4 Kamera görüntüleyici — avuç hizalama çerçevesi | 9 Avucu Tara butonu — ilerleme sayacıyla (0/5) |
| 5 Sol El / Sağ El seçici | |

6.3.2 Tarama Akışı




Sistem, avucu beş farklı açıdan tarar:





- düz
- sola eğik
- sağa eğik
- yakın mesafe
- uzak mesafe

Her taramada kamera çerçevesi beyazdan maviye dönerek başarılı yakalamayı bildirir. Ekranın altındaki yön talimatı her adımda otomatik güncellenerek kullanıcıya bir sonraki hareketi söyler.

Bu çok açılı tarama yaklaşımı, damar izinin farklı pozisyonlarda güvenilir şekilde tanınmasını sağlar.



6.3.3 PIN Oluşturma Ve Kayıt



Beş tarama tamamlandıktan sonra uygulama bir bottom sheet ile PIN oluşturma adımına geçer. Kullanıcıdan 6 haneli bir güvenlik PIN'i belirlenmesi ve ardından aynı PIN'in onay için tekrar girilmesi istenir. Her girilen hane ekranda dolu daire olarak gösterilir; PIN karakterleri hiçbir zaman açık metin olarak görüntülenmez.


Tüm adımlar başarıyla tamamlandığında yeşil onay ikonu ve "kayıt edildi" mesajıyla birlikte bir başarı diyalogu gösterilir. Diyalogda kullanıcı adı, hangi elin kaydedildiği ve kaç örnek alındığı bilgisi yer alır. "Tamam" butonuyla ana ekrana dönülür.

Kayıt akışı, kullanıcıyı adım adım yönlendiren talimatları ve anlık görsel geri bildirimleriyle teknik bilgi gerektirmeden tamamlanabilecek şekilde tasarlanmıştır. Çok açılı tarama ve PIN zorunluluğu, güvenlik katmanını biyometrik + bilgi faktörü olarak ikiye çıkarır.

6.4 ÖDEME EKRANI

Ödeme akışı üç aşamadan oluşur: tutar girişi, avuç ile kimlik doğrulama ve ödeme onayı. Avucun tanınmadığı durumlarda sistem otomatik olarak PIN tabanlı alternatif doğrulama yolunu sunar.

6.4.1 Tutar Girişi




Ödeme akışı tutar giriş ekranıyla başlar. Kullanıcı sayısal tuş takımıyla ödeme miktarını girer; tutar sıfır olduğu sürece "Avucu Okut" butonu kilitli ve gri kalır, kırmızıyla "0'dan büyük bir tutar girin" uyarısı gösterilir. Geçerli bir tutar girildiğinde buton mor renge döner ve üzerinde girilen tutarı da gösterir.

Ödeme Tutarı Ekranı Bileşenleri

- | | |
|-------------------------------------|--|
| 1 Geri butonu — önceki ekrana dönüş | 4 Tutar göstergesi — gerçek zamanlı güncellenir |
| 2 Ekran başlığı — "Ödeme Tutarı" | 5 Sayısal tuş takımı (ondalık + sil desteği) |
| 3 Yönlendirme sorusu | 6 Avucu Okut butonu — tutar girilince aktifleşir |


6.4.2 Avuç ile Kimlik Doğrulama



Tutar onaylandıktan sonra kamera ekranı açılır. Kayıt ekranından farklı olarak burada pozisyon adımları yoktur; kullanıcı avucunu çerçeveye tutar ve "Sol Avucu Tara" butonuna basar. Sistem, kameradan gelen görüntüyü kayıtlı damar izleriyle karşılaştırır.




Eşleşme başarılı olduğunda bir bottom sheet açılır: yeşil onay ikonu, doğrulanan kullanıcı adı, eşleşme yüzdesi (%94.4) ve ödeme tutarı gösterilir. "Ödeme Onaylandı" butonuna basılarak işlem tamamlanır. Eşleşme yüzdesinin ekranda görünmesi sisteme olan güveni pekiştirir.

6.4.3 Hata Durumları



Avuç tanınmazsa sistem iki katmanlı geri bildirim verir. İlk denemede kamera görüntüsü üzerinde kırmızı X ikonu belirir ve "Sol el ile kayıtlı kullanıcı bulunamadı" mesajı gösterilir. Tekrar başarısız olduğunda ek olarak üstte sarı bir banner ile flaş açılması önerilir ve "PIN ile Devam Et" butonu belirterek alternatif doğrulama yolu sunulur.


6.4.4 PIN ile Alternatif Ödeme



"PIN ile Devam Et" seçildiğinde sistem kayıtlı tüm kullanıcıları listeler. Her satırda kullanıcı adı ve hangi elin kayıtlı olduğu bilgisi yer alır. Kullanıcı listeden hesabını seçer.

Hesap seçiminin ardından kullanıcı adı ve ödeme tutarı ekranda görünür; 6 haneli PIN girilmesi beklenir. Yanlış PIN girildiğinde "Yanlış PIN, tekrar deneyin" uyarısı kırmızıyla gösterilir ve giriş alanı sıfırlanır.

ARAYÜZ TANITIMI



"PIN'i unuttum" bağlantısına tıklandığında bir uyarı diyalogu açılır: PIN kurtarmanın self-servis olmadığı belirtilir ve kullanıcı yöneticiyle iletişime yönlendirilir. Bu tasarım tercihi PIN sıfırlama sürecini kasıtlı olarak merkezi tutar; yetkisiz sıfırlama riskini ortadan kaldırır.


PIN doğru girildiğinde avuç taramasındakiyle aynı başarı ekranı açılır; ancak bu sefer "PIN ile doğrulandı" ibaresi gösterilir. Kullanıcı adı ve tutar onaylanarak "Ödeme Onaylandı" butonu aktif hale gelir.

Ödeme ekranı, güvenlik ile kullanılabilirliği dengeli biçimde ele alır. Birincil yol olan avuç taraması başarısız olduğunda sistem kullanıcıyı yönlendirmeden çıkmaz; PIN tabanlı ikincil yol sunarak ödeme akışının tamamlanmasını sağlar.

6.5 KULLANICILAR LİSTESİ EKRANI

Kullanıcılar ekranı, sisteme kayıtlı tüm bireylerin yönetildiği merkezi paneldir. Buradan kullanıcı profillerine erişilebilir, kayıtlı avuç örnekleri güncellenebilir ve kullanıcılar silinebilir.


6.5.1 Dolu Liste ve Boş Durum



Sisteme en az bir kullanıcı kayıtlı olduğunda liste görünümü aktif olur; her kullanıcı başlangıç harfinden oluşan renkli avatar, ad-soyad ve kayıtlı el bilgisiyle birlikte ayrı bir kart olarak gösterilir. Hiç kullanıcı yoksa ekran boş durum moduna geçer: büyük bir ikon, açıklayıcı bir metin ve "Kayıt Ol" butonu ile kullanıcıyı doğrudan kayıt akışına yönlendirir. Bu tasarım, boş listeyi ölü bir ekran olarak değil, bir yönlendirme noktası olarak konumlandırır.

ARAYÜZ TANITIMI



Her kullanıcı kartında üç etkileşim noktası yer alır: kartın ortasına tıklamak profil detaylarını açar, kalem ikonu düzenleme ekranına yönlendirir, çöp kutusu ikonu ise silme onayı diyalogu tetikler.



Kayıtlı Kullanıcılar Ekranı Bileşenleri




- | | |
|--|---|
| 1 Geri butonu — ana ekrana dönüş | 4 Düzenle ikonu — profil düzenleme ekranına yönlendirir |
| 2 Ekran başlığı — "Kayıtlı Kullanıcılar" | 5 Sil ikonu — onay diyalogu açarak kullanıcıyı kaldırır |
| 3 Kullanıcı kartı — avatar (baş harf), isim ve kayıtlı el bilgisi; karta tıklanarak profile ulaşılır | |

6.5.2 Profil Bilgileri ve Avuç Örnekleri



Bir kullanıcı kartına tıklandığında kayıtlı örnekler ekranı açılır. Bu ekranda kullanıcı adı, kayıtlı el tercihi, kayıtlı biyolojik verileri gösterilir. Her veri numaralandırılmış küçük resim olarak gösterilir; üzerindeki kırmızı X ile tek tek silinebilir, "+ Örnek Ekle" ile yeni tarama eklenerek veri seti genişletilebilir.

ARAYÜZ TANITIMI




Bir kullanıcı kartı üzerindeki düzenle ikonuna tıklandığında Profil ekranı açılır. Bu ekranda kullanıcı adı, kayıtlı el tercihi, biyometrik verinin kayıtlı olup olmadığı, PIN tanım durumu ve kayıt tarihi tek bir görünümde özetlenir.

Profil düzenle ekranında; avatar değiştirme, isim değiştirme, el türü değiştirme işlemleri yapılabilir. Her değişiklik sonrası 'değişiklikleri kaydet' butonu aktif olur.

Silme ikonuna basıldığında sistem bir onay diyalogu açar. Diyalogda silinecek kullanıcının adı açıkça belirtilir ve işlem İptal veya Sil seçeneklerine bırakılır. Kırmızı renklendirilmiş "Sil" butonu, eylemin geri alınamaz olduğunu görsel olarak vurgular; bu iki adımlı onay yapısı yanlışlıkla silme riskini ortadan kaldırır.

Kullanıcılar ekranı, hem operasyonel (listeye bakma, ödeme için kullanıcı seçme) hem de yönetimsel (ekleme, düzenleme, silme) işlevleri tek bir arayüzde birleştirir. Boş durum tasarımı ve silme onayı gibi detaylar kullanıcı deneyiminin uç senaryolarda da düşünüldüğünü gösterir.

6.5.3 Kullanıcı Silme




Silme ikonuna basıldığında sistem bir onay diyalogu açar. Diyalogda silinecek kullanıcının adı açıkça belirtilir ve işlem İptal veya Sil seçeneklerine bırakılır. Kırmızı renklendirilmiş "Sil" butonu, eylemin geri alınamaz olduğunu görsel olarak vurgular; bu iki adımlı onay yapısı yanlışlıkla silme riskini ortadan kaldırır.

Kullanıcılar ekranı, hem operasyonel (listeye bakma, ödeme için kullanıcı seçme) hem de yönetimsel (ekleme, düzenleme, silme) işlevleri tek bir arayüzde birleştirir. Boş durum tasarımı ve silme onayı gibi detaylar kullanıcı deneyiminin uç senaryolarda da düşünüldüğünü gösterir.

6.6 İŞLEM GEÇMİŞİ EKRANI


İşlem Geçmişi ekranı, gerçekleştirilen tüm ödeme girişimlerinin — başarılı ve başarısız — kronolojik kaydını tutar. Ekran hem denetim hem de hata ayıklama amaçlı kullanılabilir şekilde tasarlanmıştır.




İşlem Geçmişi Ekranı Bileşenleri

- | | | | |
|---|--|---|--|
| 1 | Geri butonu | 5 | Tarih grubu başlığı — işlemler güne göre gruplandırılır |
| 2 | Ekran başlığı — "İşlem Geçmişi" | 6 | Başarılı işlem kartı — yeşil onay, kullanıcı, saat, el, eşleşme %, tutar, "Onaylan |
| 3 | Geçmiş temizle ikonu — tüm kayıtları siler | 7 | Başarısız işlem kartı — kırmızı X, saat, el bilgisi, "Eşleşme bulunamadı" mesajı |
| 4 | Sekme çubuğu — Tümü / Başarılı / Başarısız (sayılarla) | | |

6.6.1 Başarılı ve Başarısız Görünümler




Başarılı işlem kartlarında yeşil onay ikonu, kullanıcı adı, saat, kullanılan el, eşleşme yüzdesi, ödeme tutarı ve "Onaylandı" etiketi yer alır. Başarısız kartlarda ise kırmızı X ikonu, saat ve el bilgisiyle birlikte "Eşleşme bulunamadı" uyarısı gösterilir; kullanıcı adı ve tutar bilinmediğinden bu alanlar boş bırakılır. Başarılı ve Başarısız sekmeleri, karma listedeki ilgili işlemleri izole ederek odaklanmış görüntüleme imkânı tanır.



Sağ üst köşedeki çöp kutusu ikonuna basıldığında "Geçmiş Temizle" onay diyalogu açılır. "Tüm işlem geçmişi silinecek." uyarısı ile İptal ve kırmızı "Temizle" butonu sunulur; geri alınamaz bir eylem olduğu için iki adımlı onay zorunludur.

ARAYÜZ TANITIMI



Geçmiş temizlendikten sonra her sekme kendi boş durum ekranını gösterir: "Tümü" sekmesi "Henüz işlem yok" mesajıyla ilk ödemenin yapılmasını bekler; "Başarılı" ve "Başarısız" sekmeleri ise ilgili kategoriye özel açıklama metniyle ayrı boş durumlar sunar. Her boş durumda bağlamsal bir ikon ve kısa bir yönlendirme cümlesi kullanılması, ekranı anlamsız bir beyaz alana dönüşmekten kurtarır.

İşlem Geçmişi ekranı, sistemi kullanan kişi sayısı arttıkça kritik önem kazanacak bir izleme aracıdır. Başarısız girişimlerin de kaydedilmesi, yalnızca kullanım istatistiklerini değil sistemin biyometrik doğrulama güvenilirliğini de değerlendirmeye olanak tanır.

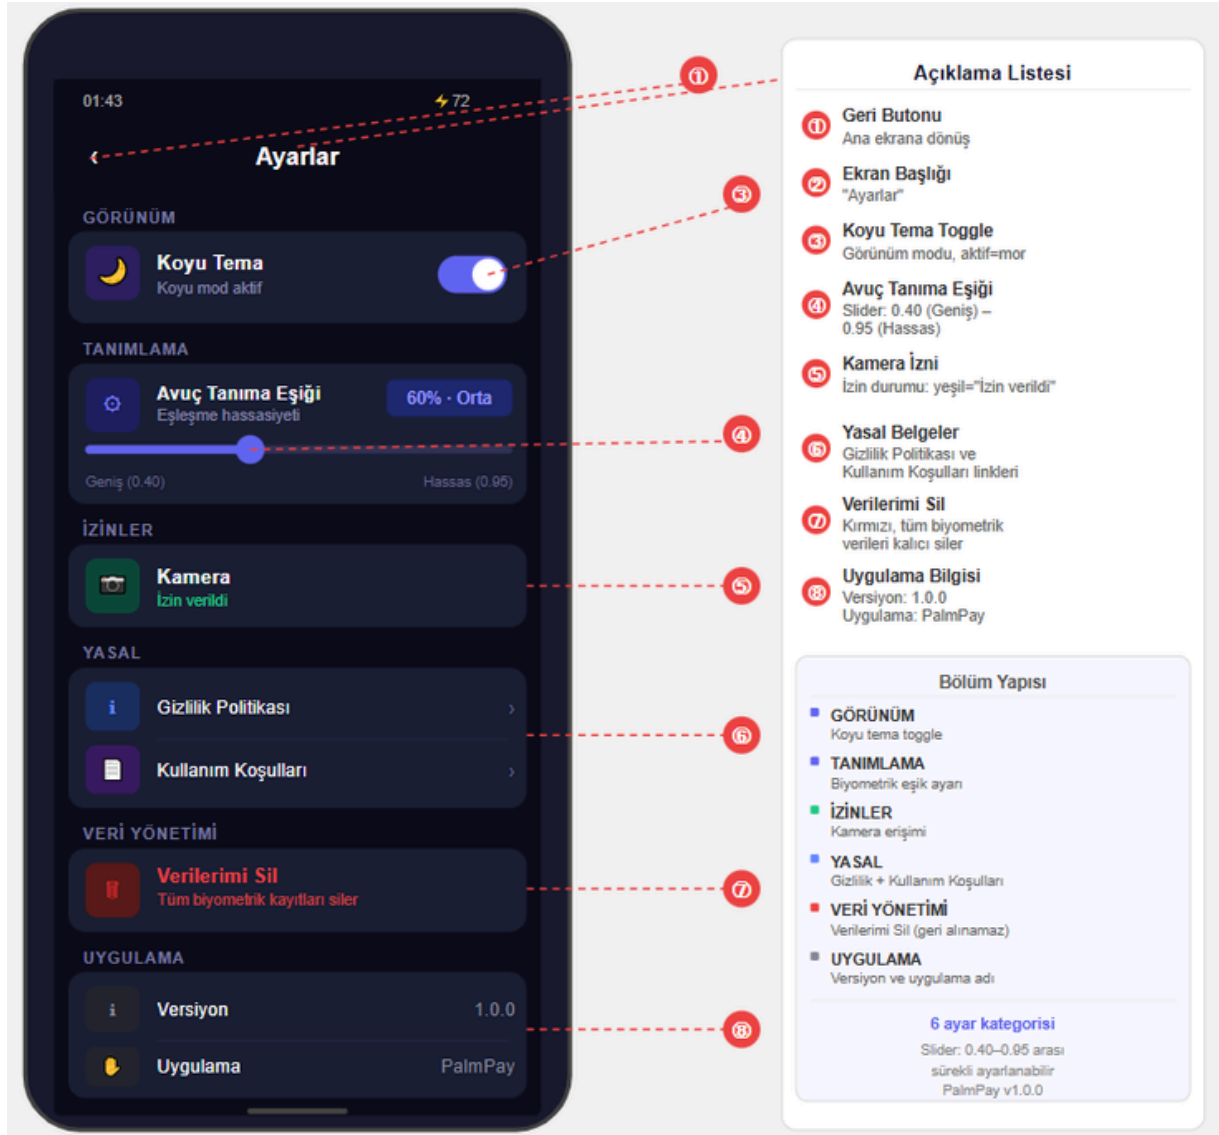
6.7 AYARLAR EKRANI

Ayarlar ekranı, uygulamanın yapılandırma seçeneklerini altı kategori altında sunar:


- Görünüm,
- Tanımlama,
- İzinler,
- Yasal,
- Veri Yönetimi,
- Uygulama.

Bu yapı; hem teknik hem de hukuki konfigürasyonu tek bir ekranda birleştirerek kullanıcıya tam kontrol sağlar.

Ekran, gri bölüm başlıkları (GÖRÜNÜM, TANIMLAMA, İZİNLER, YASAL, VERİ YÖNETİMİ, UYGULAMA) ile birbirinden ayrılmış kartlardan oluşur. Her kart solda renkli bir ikon, ortada başlık ve alt metin, sağda ise aksiyon elementi (toggle, ok, değer) barındırır. Bu tutarlı layout, farklı türdeki ayarları aynı görsel dil içinde sunmayı mümkün kılar.




6.7.1 Görünüm ve Tanımlama Ayarları



GÖRÜNÜM kategorisinde yalnızca bir seçenek yer alır: Koyu Tema toggle'ı. Toggle aktifken mor renk alır; "Koyu mod aktif" alt metni durumu metinsel olarak da teyit eder.

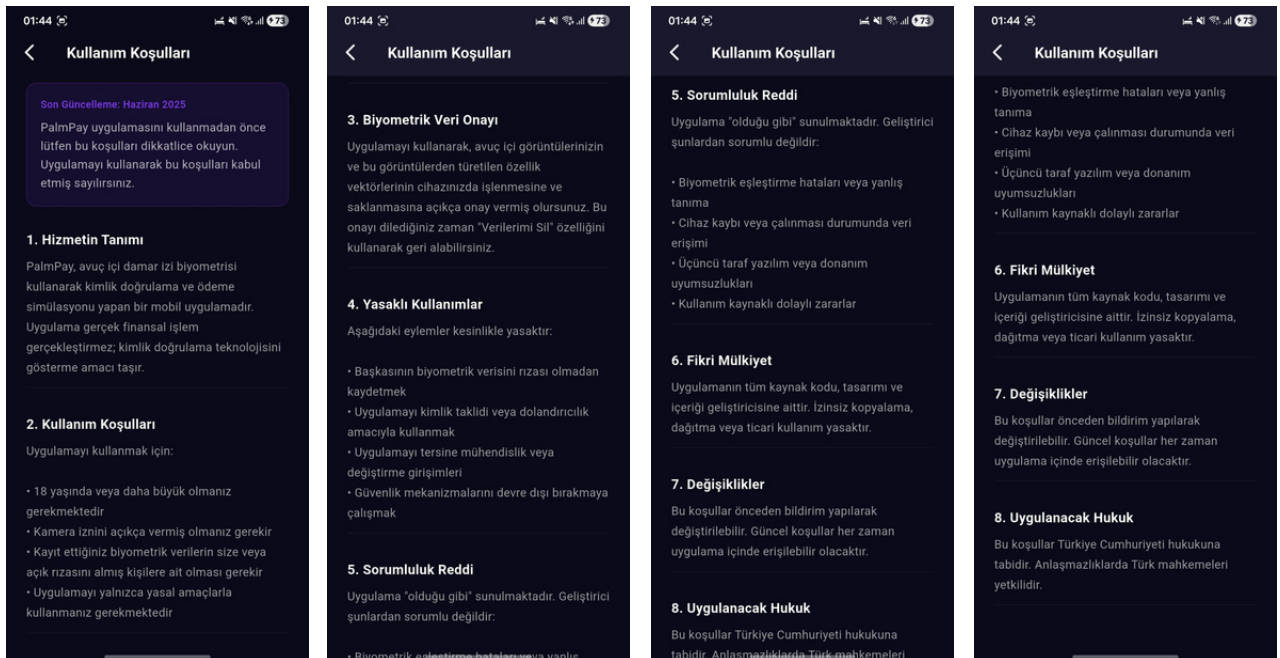
TANIMLAMA kategorisindeki Avuç Tanıma Eşiği, uygulamanın en kritik teknik parametresini kullanıcıya sunar. 0.40 (Geniş) ile 0.95 (Hassas) arasında sürüklenebilen slider, eşleşme hassasiyetini gerçek zamanlı olarak belirler; sağ üst köşedeki badge mevcut değeri ve seviyeyi ("60% · Orta", "85% · Çok Yüksek") anlık gösterir. Düşük eşik daha kolay geçiše, yüksek eşik daha güvenli ama katı doğrulamaya karşılık gelir.

6.7.2 İzinler ve Yasal Belgeler



İZİNLER kategorisi, uygulamanın talep ettiği tek sistem iznini listeler: Kamera. "İzin verildi" etiketi yeşil renkte gösterilir; izin reddedilmiş olsaydı bu alan kırmızı uyarıyla değişirdi.

YASAL kategorisi, iki ayrı belge bağlantısı içerir. Gizlilik Politikası, PalmPay'in hangi verileri topladığını (yalnızca avuç içi görüntü ve embedding vektörleri), bu verilerin nerede saklandığını (yalnızca cihaz içi SQLite) ve kullanıcının KVKK kapsamındaki haklarını dokuz madde halinde açıklar. Kullanım Koşulları belgesi ise hizmetin tanımını, yasaklı kullanımları, sorumluluk reddini ve uygulanacak hukuku (Türkiye Cumhuriyeti) sekiz madde altında düzenler.



6.7.3 Veri Yönetimi ve Uygulama Bilgisi



VERİ YÖNETİMİ kategorisindeki "Verilerimi Sil" seçeneği kırmızı renkle vurgulanır; bu, geri alınamaz bir aksiyon olduğunu görsel olarak işaret eder.


Üzerine tıklandığında " ⚠ Verileri Sil" başlıklı onay diyalogu açılır: "Tüm kayıtlı kullanıcılar ve biyometrik veriler kalıcı olarak silinecek. Bu işlem geri alınamaz." uyarısı eşliğinde İptal ve kırmızı "Evet, Sil" butonu sunulur. Bu iki adımlı onay, yanlışlıkla veri kaybını engeller.

UYGULAMA kategorisi ise bilgi amaçlıdır: Versiyon numarası (1.0.0) ve uygulama adı (PalmPay) listelenir; herhangi bir etkileşim sağlamaz.

Ayarlar ekranı, uygulamanın teknik ve hukuki altyapısını kullanıcıya şeffaf biçimde sunar. Özellikle biyometrik eşik slider'ı, sistemi farklı kullanım senaryolarına (yüksek güvenlik / yüksek kabul oranı) adapte etme imkânı tanıyan nadir bir kullanıcı dostu parametredir. Veri silme akışındaki çift onay mekanizması ve yerleşik gizlilik politikası, uygulamanın yalnızca teknik değil etik ve hukuki gereklilikleri de gözettiğini ortaya koyar.

6.8 AÇIK TEMA UYGULANMIŞ EKРАНLAR




PalmPay, Ayarlar ekranındaki Koyu Tema toggle'ı kapatıldığında açık temaya geçer. Açık temada renk paleti tamamen tersine döner: koyu (#0d0d1a) arka planlar beyaz ve açık gri tonlarına, mor vurgular ise aynı tonu koruyarak beyaz yüzeyler üzerinde belirginleşir. Uygulama bütünü bu iki tema arasında tutarlı biçimde geçiş yapar.






Açık temada tüm ekranlar; beyaz kart yüzeyleri, açık gri arka plan (#f0f0f5), siyah/koyu gri metinler ve mor (#6366F1) aksanlarla yeniden çizilir. Mor gradient "Ödeme Yap" kartı, yeşil "Onaylandı" badge'leri ve kırmızı hata göstergeleri açık temada da aynı renk kodlamasını korur; bu sayede kullanıcı her iki temada da öğrenme eğrisi olmadan uygulamayı kullanabilir.

Açık tema ayrıca daha önce yalnızca kullanıcı listesinde gördüğümüz "Düzenle" ikonuna tıklandığında açılan Profil ekranını ve biyometrik eşleşme sonrası ek güvenlik katmanı olarak devreye giren PIN ile Doğrula ekranını da gün ışığında sunar. Profil ekranında kullanıcının adı, kayıtlı eli, biyometrik veri durumu, PIN durumu ve kayıt tarihi listelenir. PIN ile Doğrula ekranında ise 6 haneli gizli PIN girişi, "PIN'i unuttum" bağlantısı ve "Hesabı değiştir" seçeneği yer alır; bu seçenek kasa başındaki kasiyer gibi senaryolarda farklı bir kullanıcı hesabına hızlıca geçiş imkânı tanır.


ARAYÜZ TANITIMI



Çift tema desteği, PalmPay'in farklı ortam koşullarına (güneşli dış mekân vs. karanlık kapalı alan) uyarlanabilir olduğunu gösterir. Temalar arasındaki geçişin anlık ve eksiksiz olması, uygulamanın renk sisteminin baştan tema-bağımsız tasarlandığının kanıtıdır.




6.9 USERFLOW (KULLANICI AKIŞ DİYAGRAMI)



ARAYÜZ TANITIMI

PalmPay — Kullanıcı Akış Şeması

Sayfa 2 / 2 — Kullanıcı Yönetimi · İşlem Geçmişi · Ayarlar



İzinler — Kamera

Uygulama yalnızca kamera iznine ihtiyaç duyar.
İzin verilmezse Kayıt ve Ödeme akışları çalışmaz.

Veri Güvenliği

Tüm biyometrik veri yalnızca cihaz içi SQLite'ta saklanır.
Bulut, üçüncü taraf veya ağ bağlantısı kullanılmaz.

🌙 / * Tema Desteği

Tüm ekranlar Koyu Tema ve Açık Tema ile çalışır. Ayarlar → Görünüm → Koyu Tema toggle üzerinden değiştirilebilir.

Gösterim

- Hub / Merkez Ekran
- Normal Ekran
- Başarılı Sonuç
- Hata / Yıkıcı Eylem
- Bilgi Ekranı

7.1. GENEL DEĞERLENDİRME

Küresel temassız ödeme pazarının 2025 itibarıyla 10 trilyon dolara yaklaşmakta olduğu ve biyometrik kimlik doğrulama sistemlerine yapılan yatırımların yıllık %18 büyüme hızıyla genişlediği bir dönemde [Mordor Intelligence, 2024], bu çalışma salt akademik bir prototip üretmenin ötesine geçerek piyasa olgunluğuna yakın bir sistem mimarisi ortaya koymuştur.

Geleneksel ödeme güvenliği katmanları — PIN kodları, manyetik şeritli kartlar ve hatta temassız parmak izi tarayıcıları — hem siber saldırılara [kart kopyalama, sosyal mühendislik] hem de pandemi sonrası şekillenen "temassız yaşam" kültürünün hijyenik gereksinimlerine yanıt vermekte yetersiz kalmaktadır. Öte yandan Apple Face ID veya Samsung Pay gibi biyometrik çözümler, pahalı donanımlara (LiDAR, kızılötesi kamera) bağımlı kalarak hem ekonomik erişilebilirlik engellerini sürdürmekte hem de verileri merkezi sunuculara taşıyarak bireysel mahremiyet riskini canlı tutmaktadır.

Bu proje söz konusu ikilem içinde özgün bir konuma yerleşmektedir: yalnızca sıradan bir RGB akıllı telefon kamerası ile çalışan, tüm biyometrik işlemleri kullanıcının cihazında tamamen çevrimdışı gerçekleştiren ve üçüncü taraf altyapısına sıfır bağımlılıkla konuşlanan bir avuç içi biyometrik ödeme sistemi.

7.1.1. Biyometrik Veri Mühendisliğinde Özgün Katkı

Projenin teknik özgünlüğünün ilk katmanı, ön işleme mimarisinde yatmaktadır. SMPD veri seti üzerinde yürütülen geliştirme sürecinde temel bir mühendislik gerçeğiyle yüzleşilmiştir: "kısıtlamasız ortam" (unconstrained environment) kavramı, literatürdeki teorik tanımlarının çok ötesinde karmaşıklık barındırmaktadır. Sabit açıdan ve sabit mesafeden alınan laboratuvar görüntülerinin aksine, gerçek dünyadaki avuç içi taramaları yüksek rotasyon varyansı, değişken aydınlatma koşulları ve kadraj dışına taşan el yapıları içermektedir.

Bu zorluğu aşmak için sıfırdan tasarlanan Adaptif HSV-Centroid Motoru, endüstri standardı MediaPipe Hand Landmarker'ın yalnızca %25 başarı gösterdiği zorlu senaryolarda %100 biyometrik kırpma başarısına ulaşmıştır. Bu rakam yalnızca bir performans metriği değil; gerçek dünya kullanılabilirliği ile akademik doğruluk arasındaki mesafenin mühendislik iradesiyle nasıl kapatılabileceğinin somut kanıtıdır.

7.1.2. Metrik Öğrenme Mimarisindeki Hibrit Yenilik

Projenin ikinci özgünlük katmanı, mimari tasarımı belirginleşmektedir. Siyam Ağları, literatürde one-shot öğrenme kapasitesiyle tanımlıdır [2][3]; ArcFace ise yüz tanıma alanında açılmal marj optimizasyonu sınıflar arası ayrımı maksimize etmesiyle öne çıkmaktadır [5]. Bu iki yaklaşımın avuç içi biyometrisi bağlamında birleştirilmesi — ArcFace'in yüz tanıma uygulamalarından çıkarılıp siyam çerçevesine entegre edilmesi — literatürdeki metodolojik boşluklardan birini dolduran özgün bir mühendislik katkısı niteliği taşımaktadır.

Bu entegrasyonun çıktıları sayısal olarak güçlüdür: aynı bireye ait avuç içi vektörleri ortalama 0.475, farklı bireylere ait vektörler ise yalnızca 0.020 benzerlik skoru üretmektedir. Sınıflar arasındaki bu 23 katlık kutuplaşma, sistemin yanlış kabul hatalarına (FAR) karşı olağandışı bir direnç sergilemesini sağlamaktadır. %95.25 doğrulama başarımı ve 0.224 EER eşiği, bu direncin matematiksel teyididir.

7.1.3. Uç Bilişim Dönüşümü ve KVKK Uyumluluğu

Avrupa Birliği Yapay Zeka Yasa'nın (EU AI Act, 2024) biyometrik sistemleri en yüksek risk kategorisine dahil etmesi ve KVKK'nın biyometrik veriler üzerindeki giderek sıkılaştan düzenlemeleri göz önüne alındığında, projenin "veri cihazı terk etmez" mimarisi yalnızca teknik bir tercih değil, normatif bir zorunluluğu önceden karşılayan ileri görüşlü bir tasarım kararı olarak değerlendirilmelidir.

PyTorch → ONNX → TFLite dönüşüm zincirinin sonunda elde edilen 11.5 MB'lık model, Android ekosistemiyle tam uyumluyken NPU ve GPU Delegate donanım hızlandırmayı da desteklemektedir. 25 ms'lik çıkarım süresi, kullanıcı deneyimini kesmeksizin biyometrik doğrulamayı ödeme akışına entegre etmektedir. Bu rakamlar; yalnızca donanım kısıtlarını çözmekle kalmayıp on-device AI standardının toplumsal benimsenmesine katkı sağlayan somut mühendislik çıktılarıdır.

7.2. PROJENİN SEKTÖREL VE BİLİMSEL KONUMLANMASI

Literatürde en yüksek başarıyı sergileyen Palm-ID sistemi [15], Vision Transformer ve CNN'i birleştiren çok modelli mimarisiyle %98.06 TAR@FAR=0.01% oranına ulaşmaktadır; ancak dağıtım karmaşıklığı ve mobil uygulanabilirliği sınırlıdır. Mevcut çalışma, daha yalın bir mimariyle (MobileNetV2 + ArcFace) bu başarımlar seviyesine yaklaşırken sistemin mobil ve çevrimdışı konuşlanabilirliğini, kullanıcı kaydında sıfır ek eğitim gereksinimini ve KVKK uyumlu çalışmasını eş zamanlı olarak karşılamaktadır. Bu bütünsel konumlandırma, projeyi literatürdeki tek boyutlu başarımlar yarışmalarının ötesine taşımakta ve "operasyonel bütünlük" ekseninde bağımsız bir özgünlük alanı tanımlamaktadır.

7.3. KULLANICI DENEYİMİ VE ARAYÜZ BÜTÜNLEŞMESİ

Derin öğrenme temelli biyometrik sistemlerin en büyük toplumsal bariyeri teknik yetersizlik değil, kullanıcı güveni eksikliğidir. Bu gerçeklik gözetilerek geliştirilen Flutter tabanlı PalmPay arayüzü, güvenlik ile erişilebilirliği eşit ağırlıkta dengelemiştir.

Onboarding akışında KVKK kapsamındaki veri işleme politikasının iki onay kutusuyla zorunlu kılınması, yasal uyumluluğu kullanıcı deneyiminin organik bir parçasına dönüştürmektedir. "Veriler cihazınızda kalır" vaadi; TFLite entegrasyonu, SQLite yerel depolama ve SHA-256 PIN şifreleme mekanizmaları sayesinde teknik bir gerçeğe dönüşmüştür: kullanıcının avuç içi verisi hiçbir zaman 512 boyutlu matematiksel bir vektörün ötesine taşınmamaktadır.

Ayarlar ekranında sunulan Avuç Tanıma Eşiği kaydırıcısı (0.40–0.95 aralığı) ise biyometrik sistemlerin güvenlik-kullanılabilirlik dengesi konusundaki literatür tartışmasını [16][17] kullanıcı arayüzüne taşıyan nadir bir tasarım kararıdır. Bu özellik; kasa ortamında hız öncelikli kullanan bir esnaf ile yüksek güvenlik gerektiren kurumsal bir kullanıcının aynı sistemi farklı konfigürasyonlarla kullanabilmesini mümkün kılmaktadır.

7.4. SİSTEMİN KISITLILIKLARI VE DÜRÜST DEĞERLENDİRME

Başarılı sonuçlara karşın, üretim ortamında karşılaşılabilecek kısıtların şeffaf biçimde belgelenmesi bilimsel dürüstlüğün ve sistemin gelişim yol haritasının temel girdisidir:

Donanım Heterojenliği: Giriş seviyesi mobil cihazlarda gözlemlenen düşük kamera çözünürlüğü ve otomatik odaklama yetersizliği, kılcal avuç içi çizgilerinin pikselleşmesine ve dolayısıyla embedding kalitesinin düşmesine yol açabilmektedir. Bu kısıt, modelin eğitim setindeki görüntülerin belirli bir minimum kalite eşiğinin üzerinde olmasından kaynaklanmakta; eğitim verisi dağılımının düşük kaliteli kamera görüntülerini de kapsayacak biçimde zenginleştirilmesiyle kısmen giderilebilir niteliktedir.

Aşırı Ortam Dinamikleri: Zifiri karanlık veya doğrudan güneş ışığı (lens parlaması) koşullarında HSV renk uzayı tabanlı yedekleme motorunun kontur tespiti yeterliliği düşmektedir. Bu durum, renk bilgisinden bağımsız derinlik veya kızılötesi tabanlı segmentasyon yaklaşımlarına olan ihtiyacı işaret etmektedir.

Sınırlı Veri Çeşitliliği: SMPD veri seti [12], Batı ve Güney Asya kökenli bireylerden oluşmaktadır; farklı cilt tonu dağılımlarını, yaş gruplarını ve çalışanlar gibi mesleki deri deformasyonlarını (nasır, kırışıklık artışı) temsil eden örneklemeler sınırlı kalmaktadır. Gerçek dünya dağıtımında demografik adalet açısından bu çeşitlilik genişletilmelidir.

7.5. GELECEK ÇALIŞMALAR

7.5.1. Canlılık Tespiti ve Sunum Saldırısı Direnci

Herhangi bir biyometrik sistemin üretim ortamındaki en kritik güvenlik açığı, gerçek bir canlı kullanıcıya ait biyometrik materyali taklit eden sunum saldırılarıdır (Presentation Attack). Mevcut sistem, bir avuç içi fotoğrafı veya ekrana yansıtılan video karesiyle kandırılmaya karşı savunmasızdır.

Bir sonraki geliştirme fazında, derin öğrenme tabanlı Canlılık Tespiti (Liveness Detection) modülünün sisteme entegre edilmesi planlanmaktadır. Bu modül için iki teknik yaklaşım araştırılacaktır: birincisi, ardışık video karelerindeki mikroskobik nabız titreşimlerini (rPPG — remote photoplethysmography) avuç içi damarlarından okuyan zaman serisi analizi; ikincisi ise avuç içi yüzeyindeki düzensiz frekans örüntülerini gerçek doku (canlı ten) ile baskı veya ekran yansıması arasında ayırtıran frekans alanı sınıflandırıcısı. ISO/IEC 30107-3 (Presentation Attack Detection) standardına uyumlu test metodolojisinin benimsenmesi, sistemin uluslararası biyometrik sertifikasyon süreçlerine hazırlanmasını da kolaylaştıracaktır.

7.5.2. Vision Transformer Entegrasyonu ve Mimari Evrim

Sandler vd. (2018) [8] tarafından önerilen MobileNetV2 mimarisi, CNN paradigmasının mobil uygulamalar için optimize edilmiş temsilcisidir. Ancak son yıllarda öz dikkat (self-attention) mekanizmasına dayanan Vision Transformer (ViT) mimarileri, uzun mesafeli pikseller arası ilişkileri yakalama kapasitesiyle biyometrik doku tanımda yeni bir başarıım çıtası belirlemeye başlamıştır [15].

Gelecek çalışmalarda, EfficientFormer-L1 veya MobileViT gibi hibrit CNN-Transformer mimarilerin mevcut MobileNetV2 omurgasının yerini alması hedeflenmektedir. Bu mimariler, avuç içi çizgilerinin hem lokal (depthwise convolution ile yakalanabilen kıvrım örüntüleri) hem de global (transformer dikkat mekanizmasıyla modellenen ana hat süreklilikler) karakterini aynı anda temsil edebilme potansiyeli taşımaktadır. Ancak bu geçişin, cihaz üzerinde çalışma kısıtlarını çiğnmeden gerçekleştirilebilmesi için model budama (pruning), bilgi damıtma (knowledge distillation) ve INT8 nicemleme (quantization) tekniklerinin birlikte uygulanması kaçınılmaz olacaktır.

7.5.3. Çok Modelli (Multi-Modal) Biyometrik Füzyon

Güvenlik sistemleri literatüründe "faktör derinliği" (defense in depth) prensibi, tek bir biyometrik modaliteye güvenilmemesini önermektedir. PalmPay'in bir sonraki evresinde, avuç içi doğrulamasının yüz tanıma (Face ID) ile eş zamanlı çalıştığı çok modellenli bir biyometrik mimariye geçilmesi planlanmaktadır.

Bu yaklaşım yalnızca güvenlik düzeyini artırmakla kalmayacak; işlem tutarına bağlı kademeli kimlik doğrulama protokollerine de zemin hazırlayacaktır: düşük tutarlı günlük ödemeler için yalnızca avuç içi taraması yeterli olurken, yüksek tutarlı işlemler veya hesap değişikliği talepleri ikinci modalite aktivasyonu gerektirecektir. Bu kademeli güvenlik mimarisi, ISO/IEC 19795 ve FIDO2 (WebAuthn) standartlarıyla uyumlu konuşlanmayı da desteklemektedir.

7.5.4. Federe Öğrenme ile Gizlilik Korumalı Model İyileştirmesi

Sistemin mevcut tasarımında biyometrik veriler cihazı terk etmemektedir; bu durum KVKK uyumluluğunu garanti altına almakta fakat aynı zamanda merkezi bir model güncelleme mekanizmasını da imkânsız kılmaktadır. Kullanıcı tabanı büyüdükçe modelin yeni demografik gruplara, cilt tonlarına ve çekim koşullarına uyum sağlaması kritik hale gelecektir.

Bu sorunu çözmek için Federe Öğrenme (Federated Learning) yaklaşımı araştırılacaktır. McMahan vd. (2017) tarafından önerilen FedAvg algoritması çerçevesinde; her cihaz kendi lokal verileri üzerinde model ağırlığı güncellemelerini hesaplamakta, yalnızca gradyan farklarını (ham veri yerine) merkezi bir sunucuya göndermekte ve sunucu bu gradyanları birleştirerek global modeli güncellemektedir. Differential Privacy teknikleriyle desteklenmiş bu mimari, kullanıcı gizliliğini hiçbir zaman tehlikeye atmadan modelin sürekli öğrenmesine olanak tanıyacaktır.

7.5.5. Kızılötesi Damar Haritası Entegrasyonu

Mevcut sistem avuç içi çizgisi (palmprint) morfolojisini baz almaktadır; ancak deri altındaki damar haritası (palm vein pattern), izin dışı elde edilmesi neredeyse imkânsız olan daha yüksek benzersizlik ve sahteciliğe dirençli bir biyometrik modalite sunmaktadır. Modern akıllı telefonlarda yaygınlaşmaya başlayan Time-of-Flight (ToF) ve Near Infrared (NIR) sensörler, bu modaliteyi tüketici elektroniğine taşıma potansiyeli taşımaktadır.

Bir sonraki araştırma fazında, Qualcomm'un Snapdragon 8 Gen serisi ve Apple A17 Pro gibi SoC'lerde sunulan NIR sensör verilerinin doğrudan model girişine beslenmesi hedeflenmektedir. RGB ve NIR modalitelerini öğrenen çift akışlı (dual-stream) bir siyam mimarisi, hem parmaklı avuç kırpması hem de damar deseni eşleştirmesini aynı çıkarım döngüsünde gerçekleştirebilecektir. Bu birleşik yaklaşım, hem güvenlik hem de kullanılabilirlik ekseninde mevcut sistemi nitel bir adım ileriye taşıyacaktır.

7.5.6. Merkez Bankası Dijital Para Birimi (CBDC) ve Web3 Cüzdan Entegrasyonu

Türkiye Cumhuriyet Merkez Bankası'nın dijital Türk Lirası (dTL) pilot çalışmaları ve Avrupa Merkez Bankası'nın dijital Euro araştırmaları, biyometrik kimlik doğrulamanın kripto-para ve CBDC ekosistemiyle kesişeceği dönemin yaklaştığını göstermektedir. PalmPay'in mevcut SQLite ve SHA-256 tabanlı güvenlik altyapısı, deterministik avuç içi imzasının (embedding vektörü) FIDO2 uyumlu bir kimlik kanıtlama mekanizmasına (attestation) dönüştürülmesine uygun bir temel sunmaktadır.

Gelecek çalışmalarda, kullanıcının 512 boyutlu biyometrik vektörünün kriptografik bir taahhüt şeması (commitment scheme) olarak işlendiği ve sıfır bilgi ispatı (Zero-Knowledge Proof) ile kimlik doğrulamasının gerçekleştirildiği bir protokol araştırılacaktır. Bu mimari; kullanıcının gerçek biyometrik verisini hiçbir zaman paylaşmadan ödeme doğrulaması yapabilmesini sağlayarak mahremiyeti koruyan finansal işlemlerin önünü açacaktır.

7.6. KAPANIŞ

Bu projenin en derin katkısı belki de ürettiği sayılardan değil, kanıtladığı bir olasılıktan kaynaklanmaktadır: yüksek güvenliqli biyometrik doğrulamanın, pahalı donanım olmadan, merkezi sunucu bağımlılığı olmadan, veri mahremiyetinden taviz vermeden ve sıradan bir akıllı telefon kamerasıyla gerçek zamanlı biçimde gerçekleştirilebileceğı.

Büyük teknoloji şirketleri biyometrik ödemeleri ekosistemlerine entegre ederken yüksek donanım gereksinimleriyle ve veri merkezileşmesiyle birlikte sunmaktadır. Bu çalışma ise tam tersini savunmaktadır: en güçlü biyometrik sistem, en az altyapıya ihtiyaç duyardır. Bu vizyon; altyapısı gelişmemiş coğrafyalardaki finansal kapsayıcılığı artırma, kronik kişisel veri ihlalleri sorununa yapısal bir alternatif sunma ve yapay zekanın kamusal yararını maksimize etme hedefleriyle de örtüşmektedir.

PalmPay, Konya Teknik Üniversitesi Bilgisayar Mühendisliği bünyesinde geliştirilen bir prototip olarak başlamıştır. Ancak temsil ettiğı mimari paradigma ve çözmeye çalıştığı problem uzayı, sektörel ölçeğe taşınmayı hak eden bir olgunluğa ulaşmıştır. Bu çalışmanın, hem akademik literatüre metodolojik katkısı hem de finansal teknoloji sektörüne pratik referans kaynağı olarak değer üretmeye devam etmesi en temel beklentidir.

KAYNAKLAR

- [1] I. Goodfellow, Y. Bengio ve A. Courville, Deep Learning. MIT Press, 2016. Çevrimiçi erişim: <https://www.deeplearningbook.org/>
- [2] J. Bromley, I. Guyon, Y. LeCun, E. Säckinger ve R. Shah, "Signature Verification using a 'Siamese' Time Delay Neural Network," Advances in Neural Information Processing Systems (NIPS), Cilt 6, ss. 737–744, 1993. <https://proceedings.neurips.cc/paper/1993/hash/288cc0ff022877bd3df94bc9360b9c5d-Abstract.html>
- [3] G. Koch, R. Zemel ve R. Salakhutdinov, "Siamese Neural Networks for One-shot Image Recognition," ICML Deep Learning Workshop, Cilt 2, 2015.
- [4] F. Schroff, D. Kalenichenko ve J. Philbin, "FaceNet: A Unified Embedding for Face Recognition and Clustering," IEEE Conference on Computer Vision and Pattern Recognition (CVPR), ss. 815–823, 2015. <https://arxiv.org/abs/1503.03832>
- [5] J. Deng, J. Guo, N. Xue ve S. Zafeiriou, "ArcFace: Additive Angular Margin Loss for Deep Face Recognition," IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), ss. 4690–4699, 2019. <https://arxiv.org/abs/1801.07698>
- [6] K. He, X. Zhang, S. Ren ve J. Sun, "Deep Residual Learning for Image Recognition," IEEE Conference on Computer Vision and Pattern Recognition (CVPR), ss. 770–778, 2016. <https://arxiv.org/abs/1512.03385>
- [7] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto ve H. Adam, "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," arXiv:1704.04861, 2017. <https://arxiv.org/abs/1704.04861>
- [8] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov ve L. C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," IEEE Conference on Computer Vision and Pattern Recognition (CVPR), ss. 4510–4520, 2018. <https://arxiv.org/abs/1801.04381>
- [9] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays vd., "MediaPipe: A Framework for Building Perception Pipelines," arXiv:1906.08172, 2019. <https://arxiv.org/abs/1906.08172>
- [10] A. Paszke, S. Gross, F. Massa vd., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," Advances in Neural Information Processing Systems (NeurIPS), Cilt 32, 2019. <https://arxiv.org/abs/1912.01703>

KAYNAKLAR

- [11] M. Abadi vd., "TensorFlow: A System for Large-Scale Machine Learning," 12th USENIX Symposium on Operating Systems Design and Implementation (OSDI), ss. 265–283, 2016. <https://www.usenix.org/conference/osdi16/technical-sessions/presentation/abadi>
- [12] M. Izadpanahkakhk, S. M. Razavi, M. Taghipour-Gorjikotaie, S. H. Zahiri ve A. Uncini, "Novel Mobile Palmprint Databases for Biometric Authentication," International Journal of Grid and Utility Computing, Cilt 10, Sayı 5, ss. 465–474, 2019. <https://www.inderscienceonline.com/doi/abs/10.1504/IJGUC.2019.102016>
- [13] M. Izadpanahkakhk, S. M. Razavi vd., "Deep Learning-Based Palmprint Recognition on Mobile Devices using SMPD," Journal of Real-Time Image Processing, 2021. https://www.researchgate.net/publication/335614137_Novel_mobile_palmprint_databases_for_biometric_authentication
- [14] J. S. Kim, G. Li, B. Son ve J. Kim, "An Empirical Study on Palmprint Recognition for Mobile Phones," IEEE Transactions on Consumer Electronics, Cilt 61, Sayı 3, ss. 311–319, 2015. <https://ieeexplore.ieee.org/document/7298090/>
- [15] S. A. Grosz, A. Godbole ve A. K. Jain, "Mobile Contactless Palmprint Recognition: Use of Multiscale, Multimodel Embeddings," IEEE Transactions on Information Forensics and Security, Cilt 19, ss. 8428–8440, 2024. <https://arxiv.org/abs/2401.08111>
- [16] A. S. Ungureanu, S. Salahuddin ve P. Corcoran, "Toward Unconstrained Palmprint Recognition on Consumer Devices: A Literature Review," IEEE Access, Cilt 8, ss. 86130–86148, 2020. <https://arxiv.org/abs/2003.00737>
- [17] D. W. S. Alausa vd., "Contactless Palmprint Recognition System: A Survey," IEEE Access, Cilt 10, ss. 132483–132505, 2022. <https://ieeexplore.ieee.org/document/9837921/>
- [18] Google LLC, "TensorFlow Lite: On-Device Machine Learning," Google AI Edge, 2017–2024. <https://www.tensorflow.org/lite>
- [19] ONNX Community, "ONNX: Open Neural Network Exchange," Linux Foundation, 2017–2024. <https://onnx.ai/>
- [20] Google LLC, "Flutter SDK: Cross-Platform Mobile Development Framework," 2018–2024. <https://flutter.dev/>
- [21] J. Yosinski, J. Clune, Y. Bengio ve H. Lipson, "How Transferable are Features in Deep Neural Networks?" Advances in Neural Information Processing Systems (NeurIPS), Cilt 27, ss. 3320–3328, 2014. <https://arxiv.org/abs/1411.1792>